

# Inférence de réseaux phylogénétiques pour la détection d'hybridations et d'introgressions

Charles-Elie Rabier

Vincent Berry, Jean-Christophe Glaszmann  
Fabio Pardi et Céline Scornavacca

*Genome Harvest / KIM Data & Life Sciences*

ISEM, Institut des Sciences de l'Evolution de Montpellier  
IMAG, Institut Montpelliérain Alexander Grothendieck

LIRMM, Laboratoire d'informatique, de Robotique et de Microélectronique  
UMR AGAP, Amélioration Génétique et adaptation des plantes, CIRAD



# Plan

- ➊ Introduction
- ➋ Inférence d'arbres d'espèces + arbres résumés en réseaux
  - La méthode SNAPP
  - Données réelles de riz
  - Données simulées
- ➌ Inférence directe de réseaux
  - Méthodes existantes
  - La nouvelle méthode SNAPPNET
    - Calcul de vraisemblance + algorithme
    - A priori sur le réseau
    - BEAST (Beauti)
    - Opérateurs pour le Markov Chain Monte-Carlo
  - Comparaison SNAPPNET vs MCMCBiMarker
  - Données réelles de riz
- ➍ Conclusion

# Plan

## 1 Introduction

## 2 Inférence d'arbres d'espèces + arbres résumés en réseaux

- La méthode SNAPP
- Données réelles de riz
- Données simulées

## 3 Inférence directe de réseaux

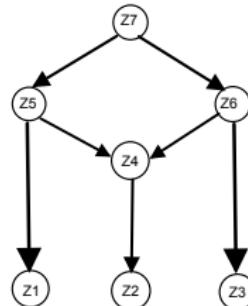
- Méthodes existantes
- La nouvelle méthode SNAPPNET
  - Calcul de vraisemblance + algorithme
  - A priori sur le réseau
  - BEAST (Beauti)
  - Opérateurs pour le Markov Chain Monte-Carlo
- Comparaison SNAPPNET vs MCMCBiMarker
- Données réelles de riz

## 4 Conclusion

# Réseaux phylogénétiques

Les réseaux phylogénétiques sont des DAG qui vont nous permettre de détecter des :

- hybridations (e.g. plantes)
- introgressions (e.g. plantes et animaux)
- transferts horizontaux (e.g. bactéries)



Quelques points importants :

- Longueur d'une arête = temps d'évolution
- Dépendance entre noeuds
- Les noeuds de réticulations ont 2 parents et représentent les évènements de réticulation
- On cherche à avoir une distribution de réseaux (incertitude sur des clades)
- Plus on collecte de données, plus on est en mesure d'inférer précisément le réseau

# La domestication du riz, un sujet de grand intérêt

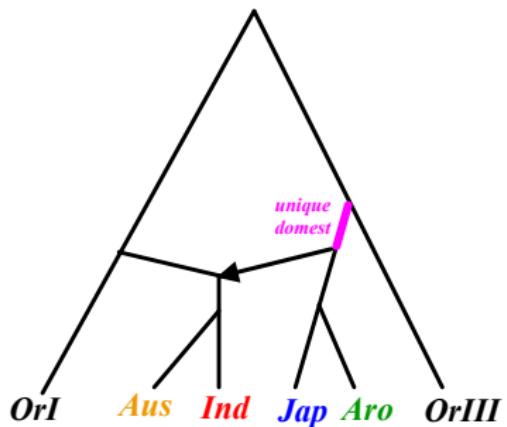
*“ La domestication est un processus transformant une espèce sauvage en une espèce dépendant de l'homme ... Elle subira une évolution adaptative afin de satisfaire les besoins de l'homme.”*

Choi et al. (MBE, 2017)

Un processus de domestication [controversé et débattu](#)

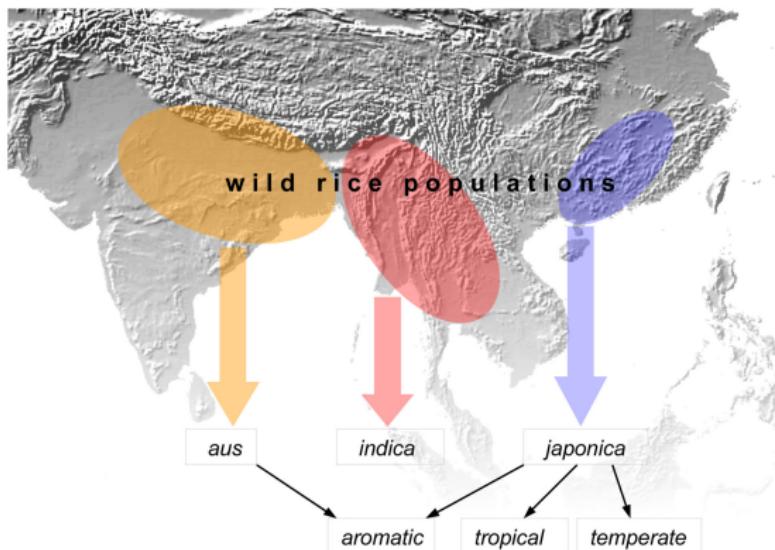
# Quelques thèses sur la domestication du riz

- Huang et al. (Nature, 2012) : *japonica domestiqué* à partir d'un riz sauvage dans le sud de la Chine, puis croisé à un sauvage dans le sud est de l'Asie, générant *indica*



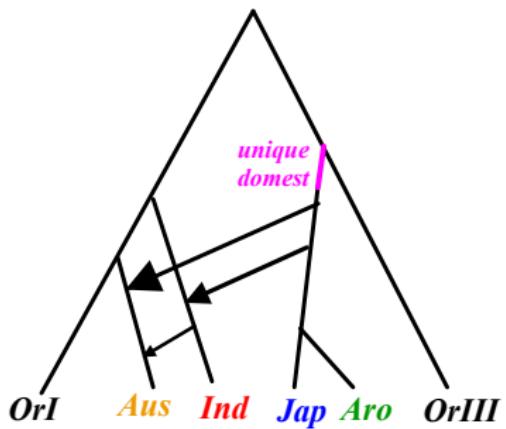
# Quelques thèses sur la domestication du riz

- Civan et al. (Nature Plants, 2015) : *indica*, *japonica* et *aus* domestiqués séparément dans différentes parties d'Asie



# Quelques thèses sur la domestication du riz

- Choi et al. (MBE, 2017) soutiennent aussi **un seul évènement de domestication (japonica)**. Introgression par hybridation de japonica et proto-indica et proto-aus, générant indica et aus

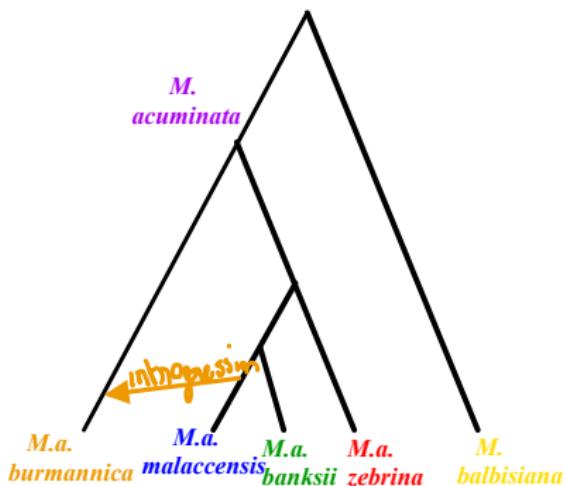


# Introgressions chez les bananes cultivées

Bananes cultivées issues de *Musa balbisiana* et *Musa acuminata*.

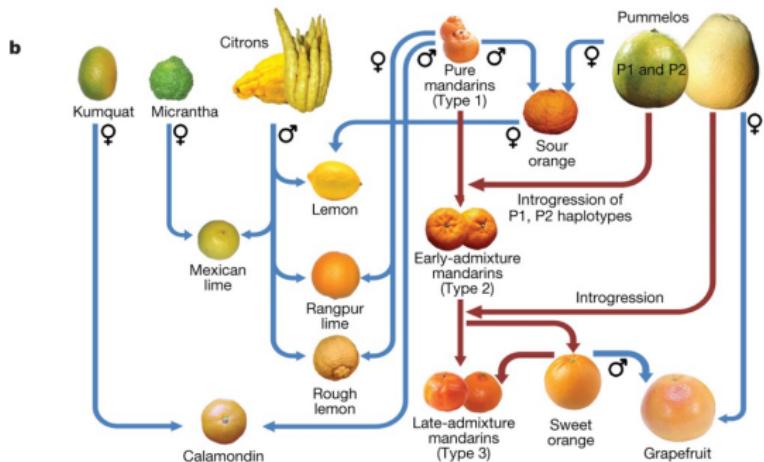
Evènement d'introgression entre *M.a.malaccensis* et *M.a.burmannica*

(Rouard et al, GBE 2018)



# Histoire évolutive chez citrus (Wu et al, Nature 2018)

Agrumes cultivés issus d'une évolution d'hybridation interspécifique impliquant cinq taxons ancestraux (*C. fortunella*, *C. micrantha*, *C. medica*, *C. reticulata*, *C. maxima*).



# Méthodes utilisées chez le riz = méthodes assez génériques

- Huang et al. (Nature, 2012)
  - Données : 446 *O.rufipogon* (sauvages) + 1083 *O.sativa* (cultivés) + 8 Millions de SNPs
  - Reconstitution d'arbres phylogénétiques par Neighbour-Joining + Analyse en Composantes Principales
- Civan et al. (Nature Plants, 2015)
  - Même jeux de données que Huang + sélection de 31 régions de faible diversité (loci de domestication)
  - Reconstitution d'arbres phylogénétiques par Neighbour-Joining + Analyse en Composantes Principales
- Wang et al. (Genome Research, 2017)
  - Reconstitution d'arbres par TreeMix :maximum de vraisemblance basé sur un modèle Gaussien de changement des fréquences d'allèles au cours du temps. Modélisation des fréquences alléliques selon un graphe. Approximations...

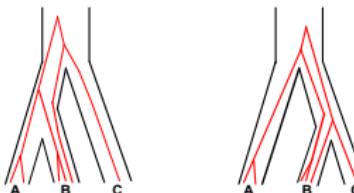
# Notre approche méthodologique

On s'intéresse à un modèle qui, outre le **tri de lignées**, considère explicitement les **mutations et hybridation**. Modélisation Bayésienne plus fine.

Nos pistes :

- 1 Inférence d'arbres d'espèces + arbres résumés en réseaux phylogénétiques

**SNAPP** (Bryant et al. 2012,  
MBE) + **SplitsTree**



- 2 Inférence directe de réseaux

**SNAPPNET** = Extension de **SNAPP** aux réseaux

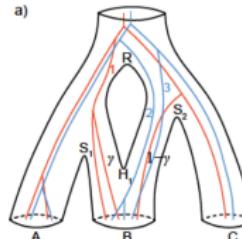


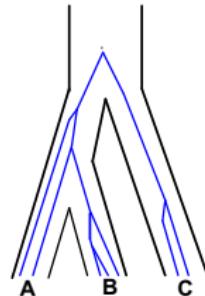
schéma tiré de Zhang et al. (2018)

# Plan

- 1 Introduction
- 2 Inférence d'arbres d'espèces + arbres résumés en réseaux
  - La méthode SNAPP
  - Données réelles de riz
  - Données simulées
- 3 Inférence directe de réseaux
  - Méthodes existantes
  - La nouvelle méthode SNAPPNET
    - Calcul de vraisemblance + algorithme
    - A priori sur le réseau
    - BEAST (Beauti)
    - Opérateurs pour le Markov Chain Monte-Carlo
  - Comparaison SNAPPNET vs MCMCBiMarker
  - Données réelles de riz
- 4 Conclusion

# Logiciel SNAPP pour l'inférence Bayésienne d'arbres (Bryant et al. 2012, MBE)

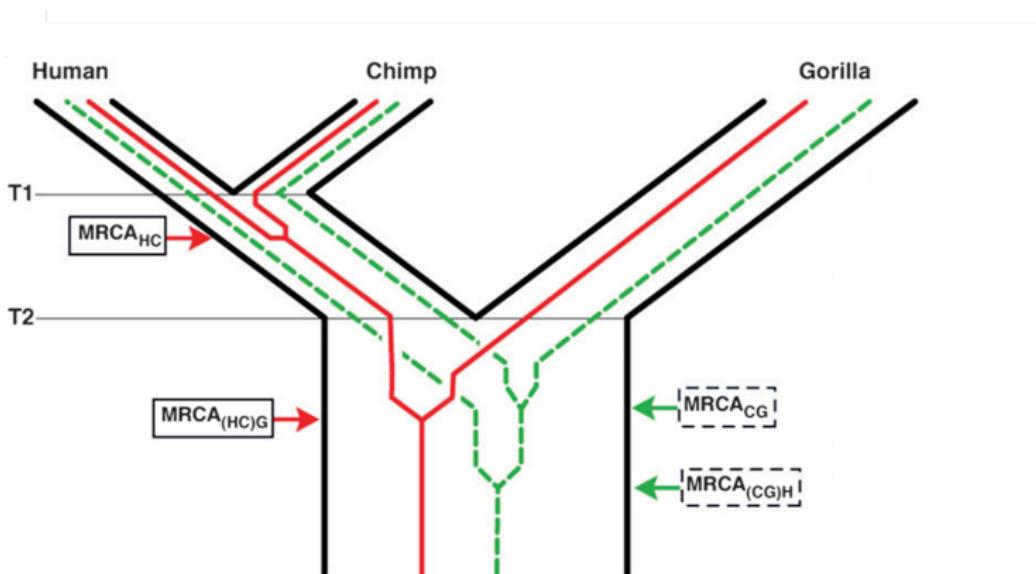
- Marqueurs bialléliques (SNPs) **indépendants** sachant l'arbre d'espèces
- Modélisation de l'arbre de locus (backward)
  - Processus de **coalescence** évoluant à l'intérieur d'un arbre d'espèces (**MultiSpecies Coalescent**)
  - Processus autorisant la **discordance** entre arbres de locus et arbres d'espèces (**tri de lignées incomplet**)



# Histoires évolutives discordantes

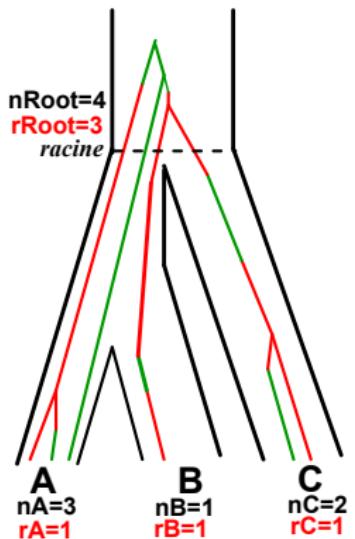
Ebersberger et al. (2007)

**Tri de lignées incomplet (ILS) :**  
processus biologique causant une **discordance** avec l'arbre de locus



# Les mutations interviennent au cours du temps

- Modélisation des données au SNP (forward)
  - mutation (**rouge** ↔ **vert**) : modèle markovien évoluant le long des branches de l'arbre de locus
  - $u$  : taux de mutation **rouge** → **vert**
  - $v$  : taux de mutation **vert** → **rouge**



- V.a. : **rRoot**, **nRoot**, **rIntNode**, **nIntNode**, **rA**, **rB**, **rC**
- pas d'aléa dans **nA**, **nB**, **nC**
- Data**=(**rA**, **rB**, **rC**)
- Vraisemblance :  $\mathbb{P}(\text{Data} | S)$  avec  $S$  arbre d'espèce

# Calcul de vraisemblance dans un arbre

- $\mathbb{P}(n_{root} = i | Count)$  calculé récursivement en remontant dans le temps (postorder)

Tavaré (Theor Pop Biol, 1984), Watterson (Theor Pop Biol, 1984), Takahata and Nei (Genetics, 1985) ...

- $\mathbb{P}(Data | Count, n_{root} = i, r_{root} = j)$  calculé récursivement en remontant dans le temps (postorder)

Slatkin (Genetics, 1996) vs. Griffiths and Tavaré (Springer, 1997)

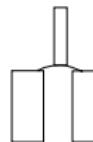
- $\mathbb{P}(r_{root} = j | n_{root} = i)$  calculé par

- la loi Binomiale :  $\mathbb{P}(r_{root} = j | n_{root} = i) = C_i^j p^j (1 - p)^{i-j}$
- la loi  $\beta(\theta, \theta)$  sur le paramètre  $p$  de la Binomiale :  
$$\mathbb{P}(r_{root} = j | n_{root} = i) = C_i^j B(j + \theta, i - j + \theta) / B(\theta, \theta)$$

- Astuces afin de raccourcir les calculs : Vraisemblances partielles...

# La statistique Bayésienne dans SNAPP

- $S$  : arbre d'espèces (topologie, longueurs de branches, tailles de populations)
- $X_i$  : données pour le locus  $i$
- $G_i$  : arbre de locus pour le locus  $i$
- $m$  loci



Par la théorème de Bayes

$$\begin{aligned} \mathbb{P}(S|X_1, \dots, X_m) &\propto \left( \prod_{i=1}^m \int_{\psi} \mathbb{P}(X_i|G_i)\mathbb{P}(G_i|S)dG_i \right) P(S) \\ &\propto \mathbb{P}(\text{Data} | S) P(S) \end{aligned}$$

SNAPP intègre sur tous les arbres de locus

Calcul de la *prior*  $P(S)$  par le processus de *naissances*

⇒ **Markov Chain Monte Carlo (MCMC)** afin d'estimer la distribution à posteriori de  $\mathbb{P}(S|X_1, \dots, X_m)$

Implémenté dans BEAST

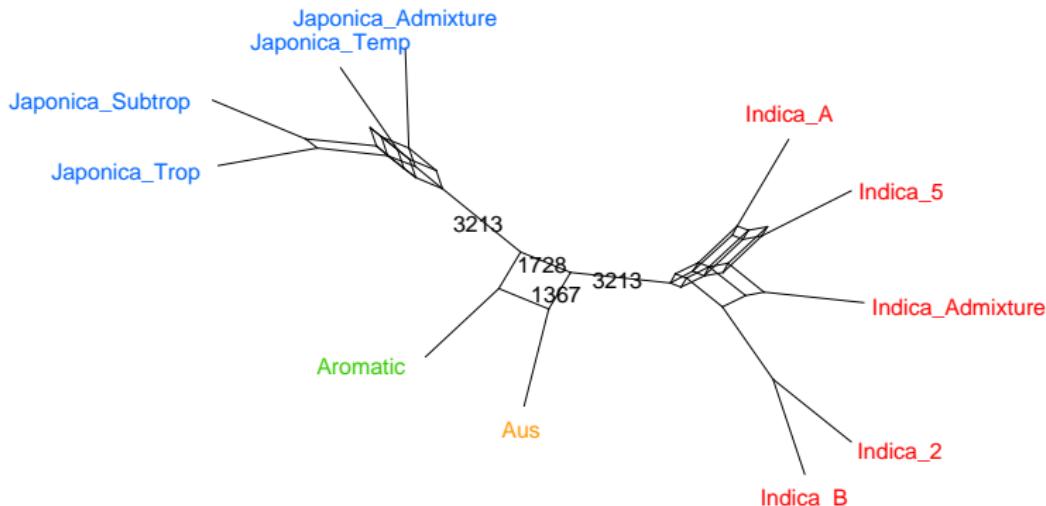
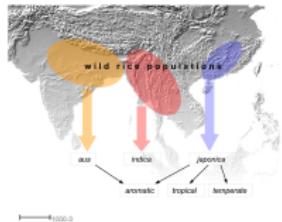
# Plan

- 1 Introduction
- 2 Inférence d'arbres d'espèces + arbres résumés en réseaux
  - La méthode SNAPP
  - Données réelles de riz
  - Données simulées
- 3 Inférence directe de réseaux
  - Méthodes existantes
  - La nouvelle méthode SNAPPNET
    - Calcul de vraisemblance + algorithme
    - A priori sur le réseau
    - BEAST (Beauti)
    - Opérateurs pour le Markov Chain Monte-Carlo
  - Comparaison SNAPPNET vs MCMCBiMarker
  - Données réelles de riz
- 4 Conclusion

# Les données de riz

- 1 Données tirées de Wang et al. (Nature 2018), 3000 variétés de riz cultivés
- 2 Prétraitement par Joao Santos (données manquantes ...)
- 3 895 977 marqueurs disponibles sur le chromosome 6
- 4 1 jeu de données proposés par JC Glaszmann (core collections)
  - 44 variétés (7 Aromatic, 7 Aus, 13 Indica, 17 Japonica)

# Chromosome 6 (données J. Santos, J-C. Glaszmann)



Conservation de 1550 SNPs (un SNP tous les 500)

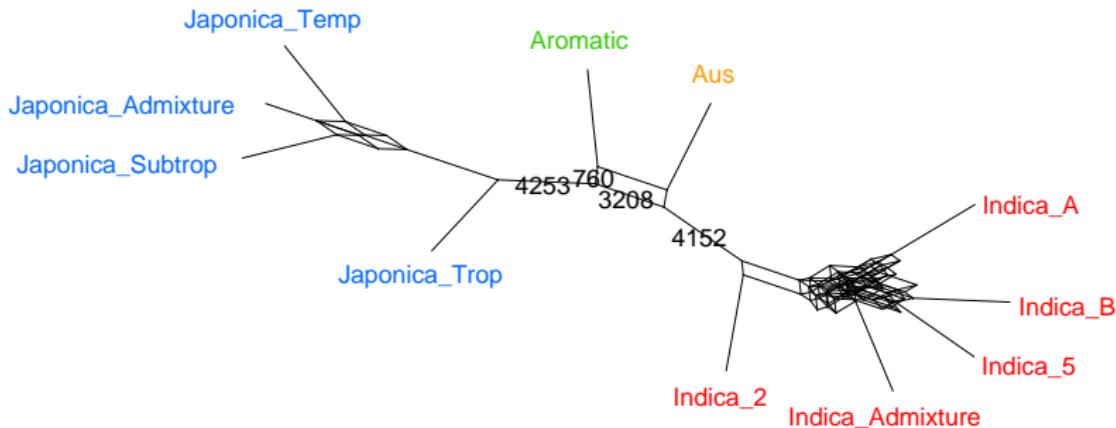
- **JDD1** (1er SNP= 1er SNP du chromosome 6)

# Chromosome 10 (données J. Santos, J-C. Glaszmann)

Conservation de 1089 SNPs (un SNP tous les 500)

- JDD2 (1er SNP= 50ème SNP du chromosome 10)

— 1000.0



# Plan

- 1 Introduction
- 2 Inférence d'arbres d'espèces + arbres résumés en réseaux
  - La méthode SNAPP
  - Données réelles de riz
  - Données simulées
- 3 Inférence directe de réseaux
  - Méthodes existantes
  - La nouvelle méthode SNAPPNET
    - Calcul de vraisemblance + algorithme
    - A priori sur le réseau
    - BEAST (Beauti)
    - Opérateurs pour le Markov Chain Monte-Carlo
  - Comparaison SNAPPNET vs MCMCBiMarker
  - Données réelles de riz
- 4 Conclusion

# Simulateur basé sur un réseau

SNAPPSimNET construit sur la base du simulateur SNAPPsim de Bryant et al. (2012)

- Génération d'arbres de locus évoluant à l'intérieur d'un réseau selon un processus de coalescence (Multispecies Network Coalescent)

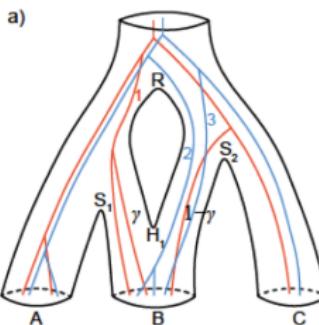


schéma tiré de Zhang et al. (2018)

- Modèle markovien évoluant le long des branches de l'arbre de locus
- Chaque arbre de locus donne un SNP
- SNAPP est fortement attiré par un scénario sous-jacent au réseau

cf. Solis-Lemus et al., Syst Biol 2016

# Plan

- 1 Introduction
- 2 Inférence d'arbres d'espèces + arbres résumés en réseaux
  - La méthode SNAPP
  - Données réelles de riz
  - Données simulées
- 3 Inférence directe de réseaux
  - Méthodes existantes
  - La nouvelle méthode SNAPPNET
    - Calcul de vraisemblance + algorithme
    - A priori sur le réseau
    - BEAST (Beauti)
    - Opérateurs pour le Markov Chain Monte-Carlo
  - Comparaison SNAPPNET vs MCMCBiMarker
  - Données réelles de riz
- 4 Conclusion

# A propos de l'inférence directe de réseaux

## Méthodes explicites pour la reconstruction de réseaux

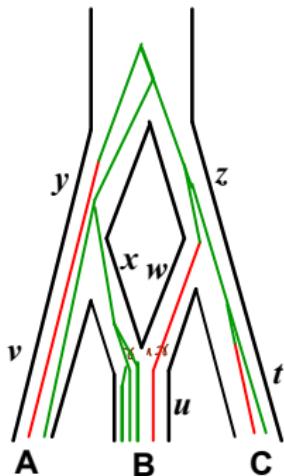
- **Approches combinatoires** qui tiennent compte de l'hybridation mais ne gèrent pas l'ILS (e.g. [Gambette et al., J. Bioinform Comput Biol 2012](#))
- **Approches basées sur un modèle stochastique avec de nombreux paramètres**
  - Méthodes de **pseudo-vraisemblance** : la vraisemblance du réseau est calculée pour des sous parties de sa topologie. Ces valeurs sont combinées par la suite (e.g. [Solis-Lemus et Ané, Plos Genetics 2016](#), [Zhu et Nakhkeh, Bioinformatics 2018](#), [Zhu et al, Bioinformatics 2019 ...](#))
  - Méthodes **maximum de vraisemblance** (e.g. [Yu et al. Plos Genetics 2012](#), [Yu et al. PNAS 2014 ...](#))
  - Méthodes **Bayésiennes** (e.g. [Wen et al., Plos Genetics 2016](#), [Zhang et al, MBE 2018](#), [Zhu et al, Plos Comp Biol 2018 ...](#))

# Plan

- ➊ Introduction
- ➋ Inférence d'arbres d'espèces + arbres résumés en réseaux
  - La méthode SNAPP
  - Données réelles de riz
  - Données simulées
- ➌ Inférence directe de réseaux
  - Méthodes existantes
  - **La nouvelle méthode SNAPPNET**
    - Calcul de vraisemblance + algorithme
    - A priori sur le réseau
    - BEAST (Beauti)
    - Opérateurs pour le Markov Chain Monte-Carlo
  - Comparaison SNAPPNET vs MCMCBiMarker
  - Données réelles de riz
- ➍ Conclusion

# Cadre d'un réseau phylogénétique

- Modélisation de l'arbre de locus (backward) :
  - processus de coalescence
  - modèle de Nakhleh au niveau du noeud de réticulation  
⇒ **Multispecies Network Coalescent**
- Modélisation des données au SNP (forward)



- V.a. : **rRoot**, **nRoot**, **rIntNode**, **nIntNode**, **rA**, **rB**, **rC**
- pas d'aléa dans **nA**, **nB**, **nC**
- Data=(rA, rB, rC)**
- Vraisemblance :  $\mathbb{P}(\text{Data} | N)$  avec N réseau

# Une méthode Bayésienne d'inférence de réseaux

- $N$  : réseau phylogénétique (topologie, longueurs de branches, tailles de populations, proba d'hybridation)
- $X_i$  : données pour le locus  $i$
- $G_i$  : arbre de locus pour le locus  $i$
- $m$  loci

$$\begin{aligned} \mathbb{P}(N|X_1, \dots, X_m) &\propto \left( \prod_{i=1}^m \int_{\psi} \mathbb{P}(X_i|G_i) \mathbb{P}(G_i|S) dG_i \right) P(N) \\ &\propto \mathbb{P}(\text{Data} | N) P(N) \end{aligned}$$

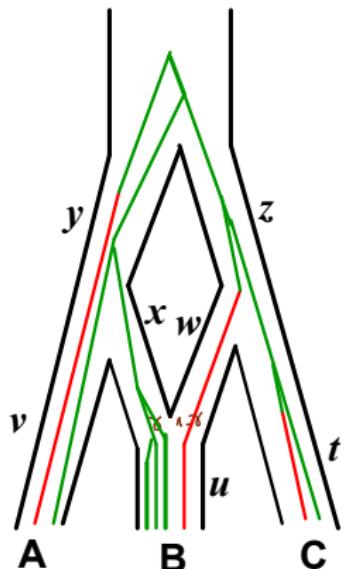
SNAPPNET intègre sur tous les arbres de locus (extension de SNAPP, Bryant et al. MBE 2012), à l'aide d'un nouvel algorithme de parcours du réseau

Calcul de la *prior*  $P(N)$  par le processus de naissances hybridation de Zhang et al. (MBE 2018)

⇒ Markov Chain Monte Carlo (MCMC) afin d'estimer la distribution à posteriori de  $\mathbb{P}(N|X_1, \dots, X_m)$

Implémenté dans BEAST

# Problème sous-jacent aux réseaux phylogénétiques



*Data<sub>z</sub>* : proportion de rouge/vert dans les espèces sous la branche *z*

*Data<sub>y</sub>* : proportion de rouge/vert dans les espèces sous la branche *y*

*Data<sub>zT</sub>* et *Data<sub>yT</sub>* ne sont pas indépendantes ...

*Data<sub>zT</sub>* et *Data<sub>yT</sub>* comprennent les allèles rouges et verts de l'espèce hybride

# Plan

- 1 Introduction
- 2 Inférence d'arbres d'espèces + arbres résumés en réseaux
  - La méthode SNAPP
  - Données réelles de riz
  - Données simulées
- 3 Inférence directe de réseaux
  - Méthodes existantes
  - La nouvelle méthode SNAPPNET
    - Calcul de vraisemblance + algorithme
    - A priori sur le réseau
    - BEAST (Beauti)
    - Opérateurs pour le Markov Chain Monte-Carlo
  - Comparaison SNAPPNET vs MCMCBiMarker
  - Données réelles de riz
- 4 Conclusion

# Calcul de la vraisemblance dans un réseau

$$\mathbb{P}(\text{Data})$$

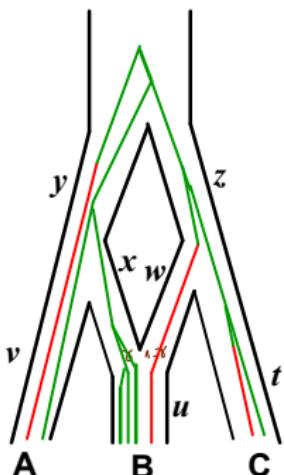
$$= \sum_i \sum_j \mathbb{P}(\text{Data} | n_{root} = i, r_{root} = j) \mathbb{P}(r_{root} = j | n_{root} = i)$$

$$\mathbb{P}(n_{root} = i)$$

$$= \sum_i \sum_j \sum_{i'} \sum_{j'} \mathbb{P}(\text{Data}_{z^T} \text{Data}_{y^T} | n_{y^T} = i', n_{z^T} = i - i', r_{y^T} = j', \\ r_{z^T} = j - j') \mathbb{P}(r_{y^T} = j', r_{z^T} = j - j' | n_{y^T} = i', n_{z^T} = i - i', r_{root} = j) \\ \mathbb{P}(n_{y^T} = i', n_{z^T} = i - i' | n_{root} = i) \mathbb{P}(r_{root} = j | n_{root} = i) \mathbb{P}(n_{root} = i)$$

- $\mathbb{P}(r_{root} = j | n_{root} = i)$  calculé par
  - la loi Binomiale :  $\mathbb{P}(r_{root} = j | n_{root} = i) = C_i^j p^j (1 - p)^{i-j}$
  - la loi  $\beta(\theta, \theta)$  sur le paramètre  $p$  de la Binomiale :
 
$$\mathbb{P}(r_{root} = j | n_{root} = i) = C_i^j B(j + \theta, i - j + \theta) / B(\theta, \theta)$$
- $\mathbb{P}(\text{Data} | n_{root} = i, r_{root} = j) \mathbb{P}(n_{root} = i)$  calculé par un nouvel algorithme

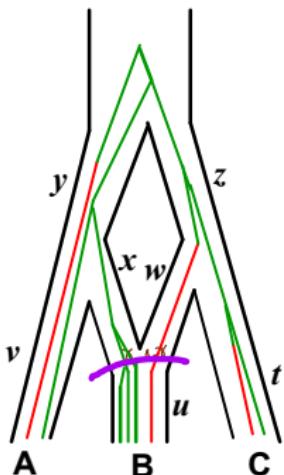
# Notre algorithme : calcul des lois jointes



Quantités calculées successivement

- (1)  $\mathbb{P}(\text{Data}_{u^T} | n_{u^T}, r_{u^T})$
- (2)  $\mathbb{P}(\text{Data}_{x^B} \text{Data}_{w^B} | n_{x^B}, r_{x^B}, n_{w^B}, r_{w^B})$
- (3)  $\mathbb{P}(\text{Data}_{x^T} \text{Data}_{w^B} | n_{x^T}, r_{x^T}, n_{w^B}, r_{w^B})$
- (4)  $\mathbb{P}(\text{Data}_{x^T} \text{Data}_{w^T} | n_{x^T}, r_{x^T}, n_{w^T}, r_{w^T})$
- (5)  $\mathbb{P}(\text{Data}_{v^T} | n_{v^T}, r_{v^T})$
- (6)  $\mathbb{P}(\text{Data}_{t^T} | n_{t^T}, r_{t^T})$
- (7)  $\mathbb{P}(\text{Data}_{y^B} \text{Data}_{w^T} | n_{y^B}, r_{y^B}, n_{w^T}, r_{w^T})$
- (8)  $\mathbb{P}(\text{Data}_{y^B} \text{Data}_{z^B} | n_{y^B}, r_{y^B}, n_{z^B}, r_{z^B})$
- (9)  $\mathbb{P}(\text{Data}_{y^T} \text{Data}_{z^B} | n_{y^T}, r_{y^T}, n_{z^B}, r_{z^B})$
- (10)  $\mathbb{P}(\text{Data}_{y^T} \text{Data}_{z^T} | n_{y^T}, r_{y^T}, n_{z^T}, r_{z^T})$
- (11)  $\mathbb{P}(\text{Data} | n_{root}, r_{root})$

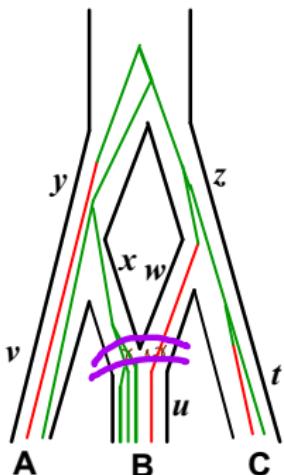
# Notre algorithme : calcul des lois jointes



Quantités calculées successivement

- (1)  $\mathbb{P}(\text{Data}_{uT} | n_{uT}, r_{uT})$
- (2)  $\mathbb{P}(\text{Data}_{xB} \text{Data}_{wB} | n_{xB}, r_{xB}, n_{wB}, r_{wB})$
- (3)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wB} | n_{xT}, r_{xT}, n_{wB}, r_{wB})$
- (4)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wT} | n_{xT}, r_{xT}, n_{wT}, r_{wT})$
- (5)  $\mathbb{P}(\text{Data}_{vT} | n_{vT}, r_{vT})$
- (6)  $\mathbb{P}(\text{Data}_{tT} | n_{tT}, r_{tT})$
- (7)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{wT} | n_{yB}, r_{yB}, n_{wT}, r_{wT})$
- (8)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{zB} | n_{yB}, r_{yB}, n_{zB}, r_{zB})$
- (9)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zB} | n_{yT}, r_{yT}, n_{zB}, r_{zB})$
- (10)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zT} | n_{yT}, r_{yT}, n_{zT}, r_{zT})$
- (11)  $\mathbb{P}(\text{Data} | n_{root}, r_{root})$

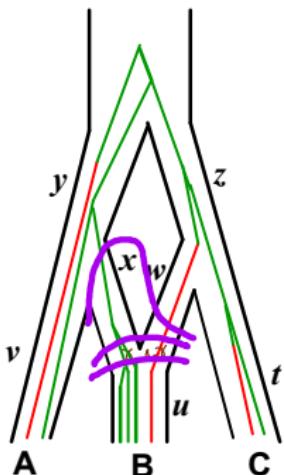
# Notre algorithme : calcul des lois jointes



Quantités calculées successivement

- (1)  $\mathbb{P}(\text{Data}_{uT} | n_{uT}, r_{uT})$
- (2)  $\mathbb{P}(\text{Data}_{xB} \text{Data}_{wB} | n_{xB}, r_{xB}, n_{wB}, r_{wB})$
- (3)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wB} | n_{xT}, r_{xT}, n_{wB}, r_{wB})$
- (4)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wT} | n_{xT}, r_{xT}, n_{wT}, r_{wT})$
- (5)  $\mathbb{P}(\text{Data}_{vT} | n_{vT}, r_{vT})$
- (6)  $\mathbb{P}(\text{Data}_{tT} | n_{tT}, r_{tT})$
- (7)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{wT} | n_{yB}, r_{yB}, n_{wT}, r_{wT})$
- (8)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{zB} | n_{yB}, r_{yB}, n_{zB}, r_{zB})$
- (9)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zB} | n_{yT}, r_{yT}, n_{zB}, r_{zB})$
- (10)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zT} | n_{yT}, r_{yT}, n_{zT}, r_{zT})$
- (11)  $\mathbb{P}(\text{Data} | n_{root}, r_{root})$

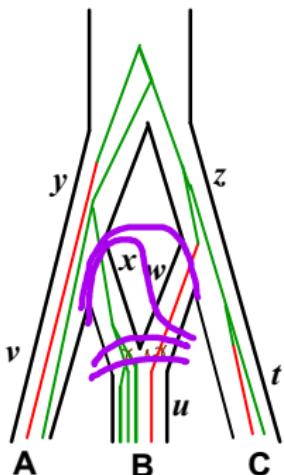
# Notre algorithme : calcul des lois jointes



Quantités calculées successivement

- (1)  $\mathbb{P}(\text{Data}_{uT} | n_{uT}, r_{uT})$
- (2)  $\mathbb{P}(\text{Data}_{x^B} \text{Data}_{w^B} | n_{x^B}, r_{x^B}, n_{w^B}, r_{w^B})$
- (3)  $\mathbb{P}(\text{Data}_{x^T} \text{Data}_{w^B} | n_{x^T}, r_{x^T}, n_{w^B}, r_{w^B})$
- (4)  $\mathbb{P}(\text{Data}_{x^T} \text{Data}_{w^T} | n_{x^T}, r_{x^T}, n_{w^T}, r_{w^T})$
- (5)  $\mathbb{P}(\text{Data}_{v^T} | n_{v^T}, r_{v^T})$
- (6)  $\mathbb{P}(\text{Data}_{t^T} | n_{t^T}, r_{t^T})$
- (7)  $\mathbb{P}(\text{Data}_{y^B} \text{Data}_{w^T} | n_{y^B}, r_{y^B}, n_{w^T}, r_{w^T})$
- (8)  $\mathbb{P}(\text{Data}_{y^B} \text{Data}_{z^B} | n_{y^B}, r_{y^B}, n_{z^B}, r_{z^B})$
- (9)  $\mathbb{P}(\text{Data}_{y^T} \text{Data}_{z^B} | n_{y^T}, r_{y^T}, n_{z^B}, r_{z^B})$
- (10)  $\mathbb{P}(\text{Data}_{y^T} \text{Data}_{z^T} | n_{y^T}, r_{y^T}, n_{z^T}, r_{z^T})$
- (11)  $\mathbb{P}(\text{Data} | n_{root}, r_{root})$

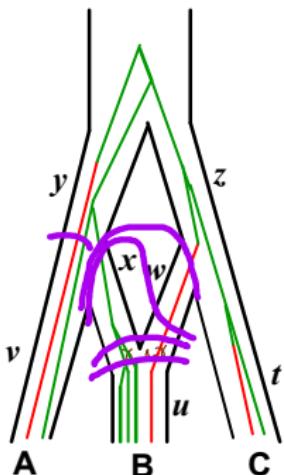
# Notre algorithme : calcul des lois jointes



Quantités calculées successivement

- (1)  $\mathbb{P}(\text{Data}_{uT} | n_{uT}, r_{uT})$
- (2)  $\mathbb{P}(\text{Data}_{xB} \text{Data}_{wB} | n_{xB}, r_{xB}, n_{wB}, r_{wB})$
- (3)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wB} | n_{xT}, r_{xT}, n_{wB}, r_{wB})$
- (4)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wT} | n_{xT}, r_{xT}, n_{wT}, r_{wT})$
- (5)  $\mathbb{P}(\text{Data}_{vT} | n_{vT}, r_{vT})$
- (6)  $\mathbb{P}(\text{Data}_{tT} | n_{tT}, r_{tT})$
- (7)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{wT} | n_{yB}, r_{yB}, n_{wT}, r_{wT})$
- (8)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{zB} | n_{yB}, r_{yB}, n_{zB}, r_{zB})$
- (9)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zB} | n_{yT}, r_{yT}, n_{zB}, r_{zB})$
- (10)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zT} | n_{yT}, r_{yT}, n_{zT}, r_{zT})$
- (11)  $\mathbb{P}(\text{Data} | n_{root}, r_{root})$

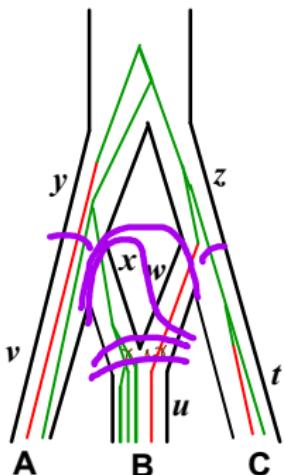
# Notre algorithme : calcul des lois jointes



Quantités calculées successivement

- (1)  $\mathbb{P}(\text{Data}_{uT} | n_{uT}, r_{uT})$
- (2)  $\mathbb{P}(\text{Data}_{xB} \text{Data}_{wB} | n_{xB}, r_{xB}, n_{wB}, r_{wB})$
- (3)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wB} | n_{xT}, r_{xT}, n_{wB}, r_{wB})$
- (4)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wT} | n_{xT}, r_{xT}, n_{wT}, r_{wT})$
- (5)  $\mathbb{P}(\text{Data}_{vT} | n_{vT}, r_{vT})$
- (6)  $\mathbb{P}(\text{Data}_{tT} | n_{tT}, r_{tT})$
- (7)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{wT} | n_{yB}, r_{yB}, n_{wT}, r_{wT})$
- (8)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{zB} | n_{yB}, r_{yB}, n_{zB}, r_{zB})$
- (9)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zB} | n_{yT}, r_{yT}, n_{zB}, r_{zB})$
- (10)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zT} | n_{yT}, r_{yT}, n_{zT}, r_{zT})$
- (11)  $\mathbb{P}(\text{Data} | n_{root}, r_{root})$

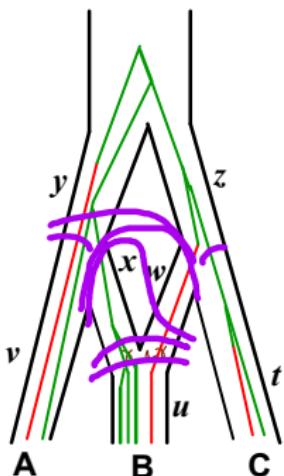
# Notre algorithme : calcul des lois jointes



Quantités calculées successivement

- (1)  $\mathbb{P}(\text{Data}_{uT} | n_{uT}, r_{uT})$
- (2)  $\mathbb{P}(\text{Data}_{xB} \text{Data}_{wB} | n_{xB}, r_{xB}, n_{wB}, r_{wB})$
- (3)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wB} | n_{xT}, r_{xT}, n_{wB}, r_{wB})$
- (4)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wT} | n_{xT}, r_{xT}, n_{wT}, r_{wT})$
- (5)  $\mathbb{P}(\text{Data}_{vT} | n_{vT}, r_{vT})$
- (6)  $\mathbb{P}(\text{Data}_{tT} | n_{tT}, r_{tT})$
- (7)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{wT} | n_{yB}, r_{yB}, n_{wT}, r_{wT})$
- (8)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{zB} | n_{yB}, r_{yB}, n_{zB}, r_{zB})$
- (9)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zB} | n_{yT}, r_{yT}, n_{zB}, r_{zB})$
- (10)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zT} | n_{yT}, r_{yT}, n_{zT}, r_{zT})$
- (11)  $\mathbb{P}(\text{Data} | n_{root}, r_{root})$

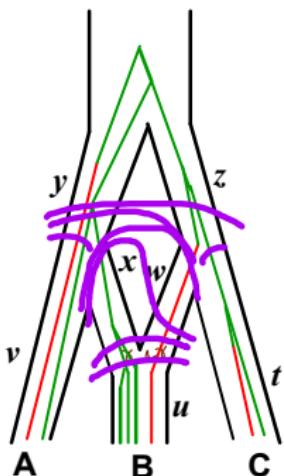
# Notre algorithme : calcul des lois jointes



Quantités calculées successivement

- (1)  $\mathbb{P}(\text{Data}_{uT} | n_{uT}, r_{uT})$
- (2)  $\mathbb{P}(\text{Data}_{xB} \text{Data}_{wB} | n_{xB}, r_{xB}, n_{wB}, r_{wB})$
- (3)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wB} | n_{xT}, r_{xT}, n_{wB}, r_{wB})$
- (4)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wT} | n_{xT}, r_{xT}, n_{wT}, r_{wT})$
- (5)  $\mathbb{P}(\text{Data}_{vT} | n_{vT}, r_{vT})$
- (6)  $\mathbb{P}(\text{Data}_{tT} | n_{tT}, r_{tT})$
- (7)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{wT} | n_{yB}, r_{yB}, n_{wT}, r_{wT})$
- (8)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{zB} | n_{yB}, r_{yB}, n_{zB}, r_{zB})$
- (9)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zB} | n_{yT}, r_{yT}, n_{zB}, r_{zB})$
- (10)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zT} | n_{yT}, r_{yT}, n_{zT}, r_{zT})$
- (11)  $\mathbb{P}(\text{Data} | n_{root}, r_{root})$

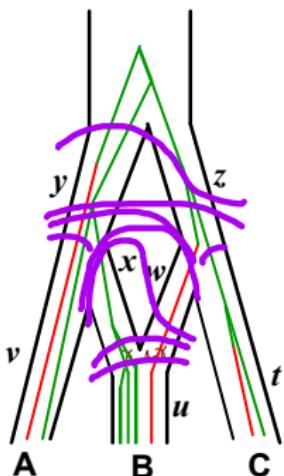
# Notre algorithme : calcul des lois jointes



Quantités calculées successivement

- (1)  $\mathbb{P}(\text{Data}_{uT} | n_{uT}, r_{uT})$
- (2)  $\mathbb{P}(\text{Data}_{xB} \text{Data}_{wB} | n_{xB}, r_{xB}, n_{wB}, r_{wB})$
- (3)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wB} | n_{xT}, r_{xT}, n_{wB}, r_{wB})$
- (4)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wT} | n_{xT}, r_{xT}, n_{wT}, r_{wT})$
- (5)  $\mathbb{P}(\text{Data}_{vT} | n_{vT}, r_{vT})$
- (6)  $\mathbb{P}(\text{Data}_{tT} | n_{tT}, r_{tT})$
- (7)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{wT} | n_{yB}, r_{yB}, n_{wT}, r_{wT})$
- (8)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{zB} | n_{yB}, r_{yB}, n_{zB}, r_{zB})$
- (9)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zB} | n_{yT}, r_{yT}, n_{zB}, r_{zB})$
- (10)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zT} | n_{yT}, r_{yT}, n_{zT}, r_{zT})$
- (11)  $\mathbb{P}(\text{Data} | n_{root}, r_{root})$

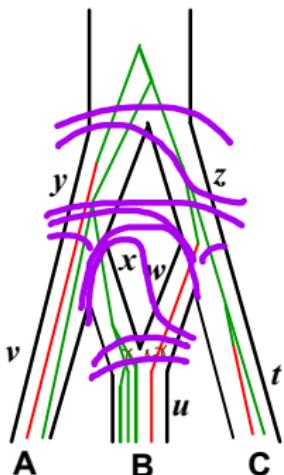
# Notre algorithme : calcul des lois jointes



Quantités calculées successivement

- (1)  $\mathbb{P}(\text{Data}_{uT} | n_{uT}, r_{uT})$
- (2)  $\mathbb{P}(\text{Data}_{xB} \text{Data}_{wB} | n_{xB}, r_{xB}, n_{wB}, r_{wB})$
- (3)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wB} | n_{xT}, r_{xT}, n_{wB}, r_{wB})$
- (4)  $\mathbb{P}(\text{Data}_{xT} \text{Data}_{wT} | n_{xT}, r_{xT}, n_{wT}, r_{wT})$
- (5)  $\mathbb{P}(\text{Data}_{vT} | n_{vT}, r_{vT})$
- (6)  $\mathbb{P}(\text{Data}_{tT} | n_{tT}, r_{tT})$
- (7)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{wT} | n_{yB}, r_{yB}, n_{wT}, r_{wT})$
- (8)  $\mathbb{P}(\text{Data}_{yB} \text{Data}_{zB} | n_{yB}, r_{yB}, n_{zB}, r_{zB})$
- (9)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zB} | n_{yT}, r_{yT}, n_{zB}, r_{zB})$
- (10)  $\mathbb{P}(\text{Data}_{yT} \text{Data}_{zT} | n_{yT}, r_{yT}, n_{zT}, r_{zT})$
- (11)  $\mathbb{P}(\text{Data} | n_{root}, r_{root})$

# Notre algorithme : calcul des lois jointes



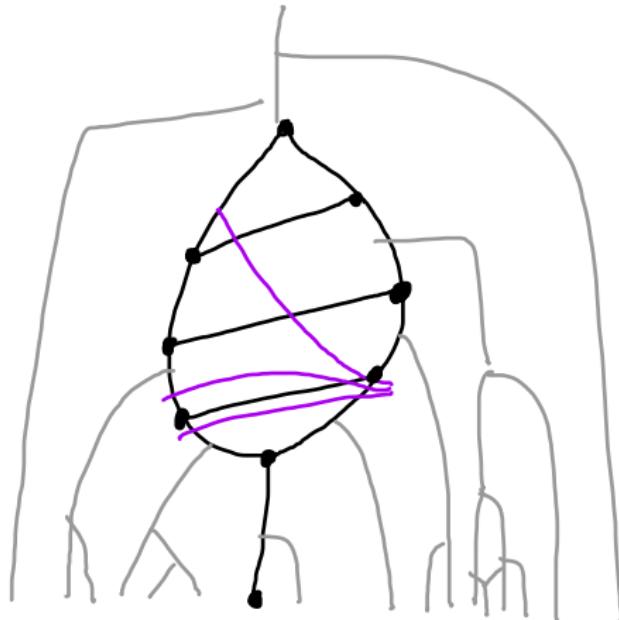
Quantités calculées successivement

- (1)  $\mathbb{P}(\text{Data}_{u^T} | n_{u^T}, r_{u^T})$
- (2)  $\mathbb{P}(\text{Data}_{x^B} \text{Data}_{w^B} | n_{x^B}, r_{x^B}, n_{w^B}, r_{w^B})$
- (3)  $\mathbb{P}(\text{Data}_{x^T} \text{Data}_{w^B} | n_{x^T}, r_{x^T}, n_{w^B}, r_{w^B})$
- (4)  $\mathbb{P}(\text{Data}_{x^T} \text{Data}_{w^T} | n_{x^T}, r_{x^T}, n_{w^T}, r_{w^T})$
- (5)  $\mathbb{P}(\text{Data}_{v^T} | n_{v^T}, r_{v^T})$
- (6)  $\mathbb{P}(\text{Data}_{t^T} | n_{t^T}, r_{t^T})$
- (7)  $\mathbb{P}(\text{Data}_{y^B} \text{Data}_{w^T} | n_{y^B}, r_{y^B}, n_{w^T}, r_{w^T})$
- (8)  $\mathbb{P}(\text{Data}_{y^B} \text{Data}_{z^B} | n_{y^B}, r_{y^B}, n_{z^B}, r_{z^B})$
- (9)  $\mathbb{P}(\text{Data}_{y^T} \text{Data}_{z^B} | n_{y^T}, r_{y^T}, n_{z^B}, r_{z^B})$
- (10)  $\mathbb{P}(\text{Data}_{y^T} \text{Data}_{z^T} | n_{y^T}, r_{y^T}, n_{z^T}, r_{z^T})$
- (11)  $\mathbb{P}(\text{Data} | n_{root}, r_{root})$

Nous cherchons à minimiser le nombre d'arêtes à considérer simultanément dans nos calculs de probabilités

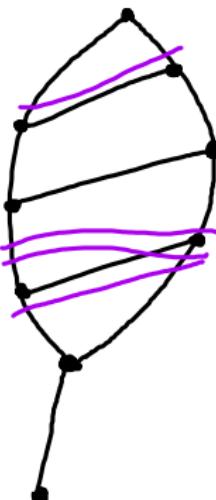
Un parcours à éviter

Un maximum de 5 arêtes



Un parcours intéressant

Un maximum de 3 arêtes



# Plan

## 1 Introduction

## 2 Inférence d'arbres d'espèces + arbres résumés en réseaux

- La méthode SNAPP
- Données réelles de riz
- Données simulées

## 3 Inférence directe de réseaux

- Méthodes existantes
- La nouvelle méthode SNAPPNET
  - Calcul de vraisemblance + algorithme
  - *A priori sur le réseau*
  - BEAST (Beauti)
  - Opérateurs pour le Markov Chain Monte-Carlo
- Comparaison SNAPPNET vs MCMCBiMarker
- Données réelles de riz

## 4 Conclusion

# A propos du prior sur le réseau (Zhang et al., MBE 2018)

Rappel au niveau du posterior :

$$\mathbb{P}(N|X_1, \dots, X_m) \propto \mathbb{P}(\text{Data} | N) P(N)$$

Le **prior** est  $P(N)$ .

Le processus de naissance hybridation dépend de paramètres  $\nu$  et  $\lambda$ .

Des lois sont imposées sur  $\nu$  et  $\lambda$  : on parle d'**hyper prior**.

$$\mathbb{P}(N, X, Y) = \mathbb{P}(N | X, Y) P(X) P(Y)$$

- $X$  : v.a. pour la valeur  $\lambda - \nu$
- la loi choisie pour  $X$  est une **loi exponentielle**
- $Y$  : v.a. pour la valeur  $\frac{\nu}{\lambda}$
- la loi choisie pour  $Y$  est une **loi Beta**

# Plan

- 1 Introduction
- 2 Inférence d'arbres d'espèces + arbres résumés en réseaux
  - La méthode SNAPP
  - Données réelles de riz
  - Données simulées
- 3 Inférence directe de réseaux
  - Méthodes existantes
  - La nouvelle méthode SNAPPNET
    - Calcul de vraisemblance + algorithme
    - A priori sur le réseau
    - BEAST (Beauti)
    - Opérateurs pour le Markov Chain Monte-Carlo
  - Comparaison SNAPPNET vs MCMCBiMarker
  - Données réelles de riz
- 4 Conclusion

# A propos du xml de SNAPPNET (Add On pour Beast)

```
<distribution id="networkPrior"
spec="speciesnetwork.BirthHybridizationModel"
network="@network :species" netDiversification="@netDivRate :species"
turnOver="@turnOverRate :species"/>
<prior id="netDivPrior" name="distribution" x="@netDivRate :species">
<Exponential id="exponential.01" name="distr" mean="10.0"/>
</prior>
<prior id="turnOverPrior" name="distribution" x="@turnOverRate :species">
<Beta id="betadistr.01" name="distr" alpha="1.0" beta="1.0"/>
</prior>
```

Obtention du xml de SNAPPNET :

BEAUti — Bayesian Evolutionary Analysis Utility.

This program is used to import data, design the analysis, and generate the BEAST control file.



# BEAUi : correspondance entre variétés et espèces

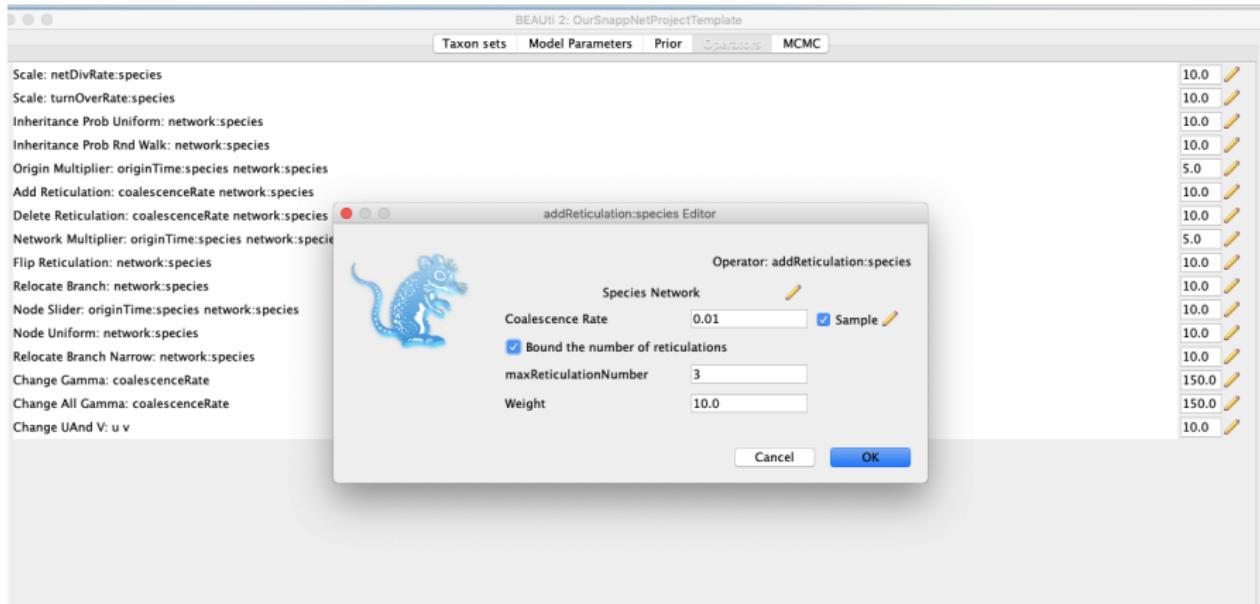
BEAUi 2: OurSnappNetProjectTemplate

Taxon sets Model Parameters Prior MCMC

Taxon	Species/Population
B204_Jap	Jap
IRIS_313-11058_Aus	Aus
IRIS_313-11062_Aro	Aro
IRIS_313-11737_Aus	Aus
IRIS_313-11796_Ind	Ind
IRIS_313-11819_Ind	Ind
IRIS_313-11825_Aro	Aro
IRIS_313-11924_Jap	Jap
W1559_Or1	Or1
W1943_Or3	Or3
W2036_Or3	Or3
W3105_Or1	Or1

Fill down Guess

## BEAUti : choix du nombre maximum de réticulations



# Plan

- 1 Introduction
- 2 Inférence d'arbres d'espèces + arbres résumés en réseaux
  - La méthode SNAPP
  - Données réelles de riz
  - Données simulées
- 3 Inférence directe de réseaux
  - Méthodes existantes
  - La nouvelle méthode SNAPPNET
    - Calcul de vraisemblance + algorithme
    - A priori sur le réseau
    - BEAST (Beauti)
    - Opérateurs pour le Markov Chain Monte-Carlo
  - Comparaison SNAPPNET vs MCMCBiMarker
  - Données réelles de riz
- 4 Conclusion

# A propos des opérateurs implémentés

16 opérateurs pour l'échantillonnage par MCMC (Bryant et al, MBE 2012 ; Zhang et al., MBE 2017)

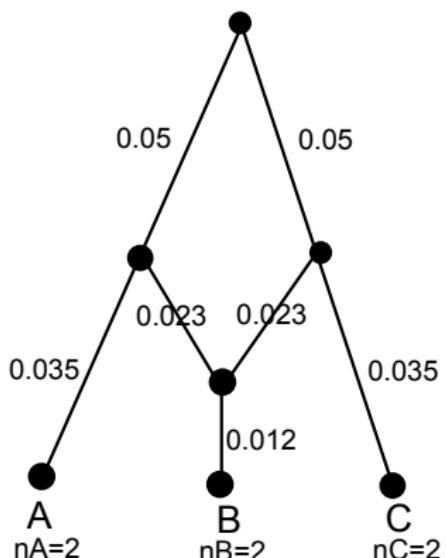
## Opérateurs de changement topologique

- **addReticulation** : ajout d'un noeud de réticulation
- **deleteReticulation** : suppression d'un noeud de réticulation
- **flipReticulation** : inversion de l'orientation d'une branche de réticulation
- **relocateBranch**

## Autres opérateurs, comme par exemple

- **MutationMover** : changement des valeurs des taux de mutation **u** (**rouge** → **vert**) et **v** (**vert** → **rouge**), sous la contrainte  $\frac{2uv}{u+v} = 1$
- **ChangeTheta** : changement de la taille de population  $\theta$  liée à une branche
- **ChangeAllTheta** : changement de toutes les tailles de population  $\theta$
- **turnOverScale** : changement de la valeur du paramètre  $\frac{\nu}{\lambda}$  lié au processus de naissance hybridation ( $\nu$  taux d'hybridation,  $\lambda$  taux de spéciation)
- **divRateScale** : changement de valeur du paramètre  $\lambda - \nu$  lié au processus de naissance hybridation

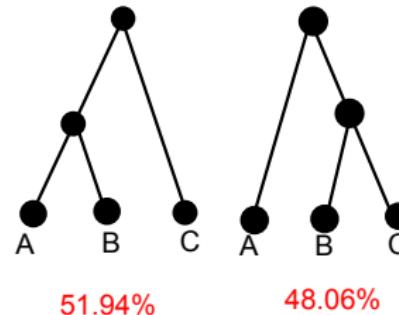
# Un exemple de réseau étudié par simulation



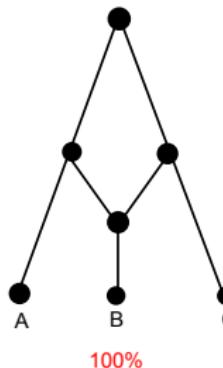
- Longueurs de branches en nombre de mutations par site
- $n_A=2, n_B=2, n_C=2$
- 1 000 sites ou 10 000 sites
- Tailles de population  $\theta$  égales à 0.005 ou 0.05
- T : temps de coalescence entre 2 lignées (en mutations par site)
  - si  $\theta = 0.005$ , alors  $E(T) = 0.005/2 = 0.0025$
  - si  $\theta = 0.05$ , alors  $E(T) = 0.005/2 = 0.025$

# Réseaux échantillonnés par MCMC

- 1 000 sites,  $\theta = 0.005$



- 10 000 sites,  $\theta = 0.005$
- 1 000 sites,  $\theta = 0.05$
- 10 000 sites,  $\theta = 0.05$

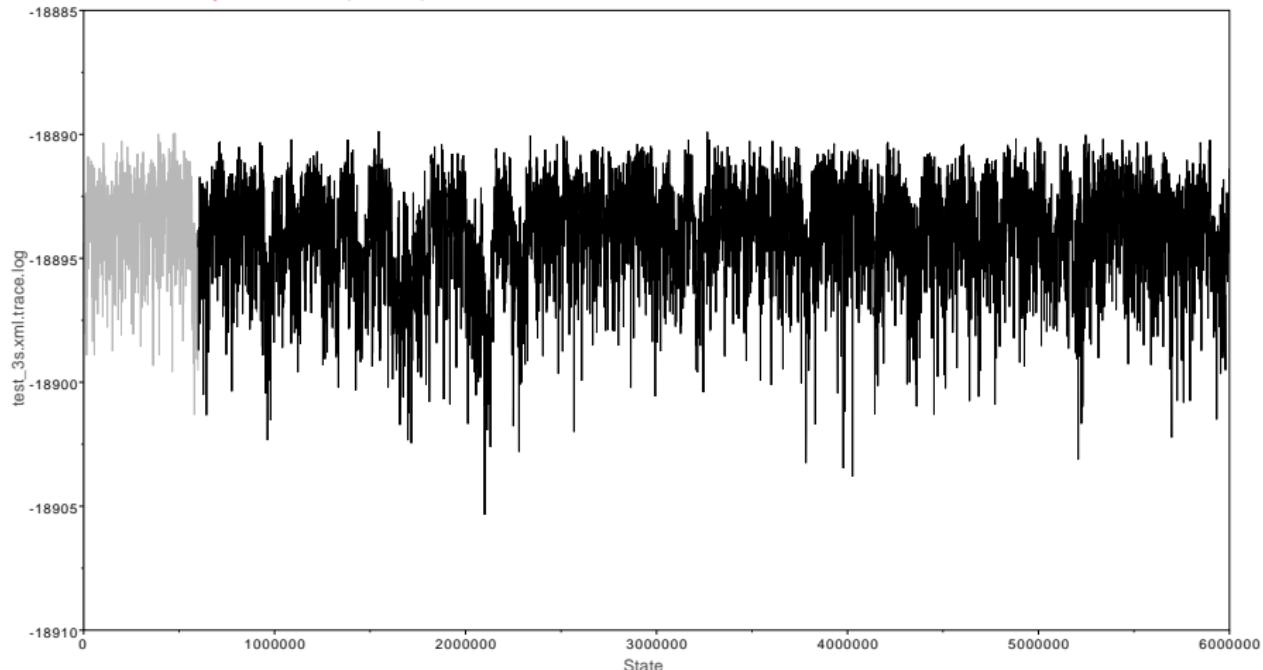


Avec une taille de population plus importante,  
on a besoin de moins de sites pour retrouver le réseau !!!

# Trace plot

Cas 10 000 sites,  $\theta = 0.05$

Analyse avec le logiciel Tracer  
Effective Sample Size (ESS) = 413

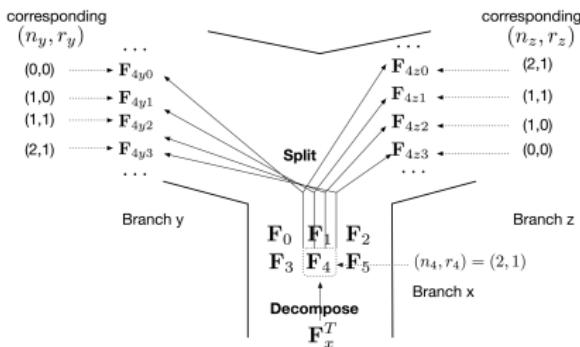


# Plan

- 1 Introduction
- 2 Inférence d'arbres d'espèces + arbres résumés en réseaux
  - La méthode SNAPP
  - Données réelles de riz
  - Données simulées
- 3 Inférence directe de réseaux
  - Méthodes existantes
  - La nouvelle méthode SNAPPNET
    - Calcul de vraisemblance + algorithme
    - A priori sur le réseau
    - BEAST (Beauti)
    - Opérateurs pour le Markov Chain Monte-Carlo
  - Comparaison SNAPPNET vs MCMCBiMarker
  - Données réelles de riz
- 4 Conclusion

# La méthode MCMCBiMarkers de Zhu et al (Plos Comput Biol, 2018)

- Enumération de toutes les partitions possibles des lignées au sein du réseau



MCMCBiMarkers implémenté dans PHYLONET

# Complexité pour le calcul de vraisemblance de l'ordre : MCMCBiMarkers vs SNAPPNET

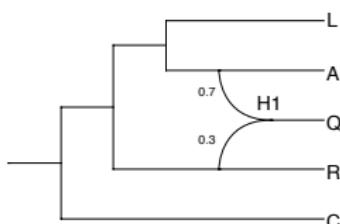
## Notations

- $m$  : nombre de noeuds
- $n$  : nombre maximal de variétés dans une espèce

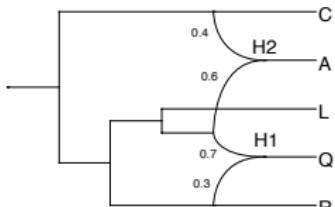
## Complexités

- MCMCBiMarkers :  $O(mn^{4k+4})$ ,
  - $k$  : niveau du réseau
- SNAPPNET :  $O(mn^{2k'+2})$ 
  - $k'$  : nombre maximum de branches simultanément considérées dans les vraisemblances partielles

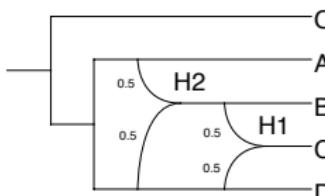
# 3 Réseaux étudiés par simulation



Réseau A



Réseau B



Réseau C

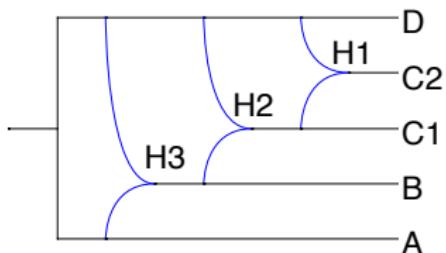
Réseaux A et B tirés de Zhu et al (Plos Comput Biol, 2018)

## MCMCBiMarkers vs SNAPPNET

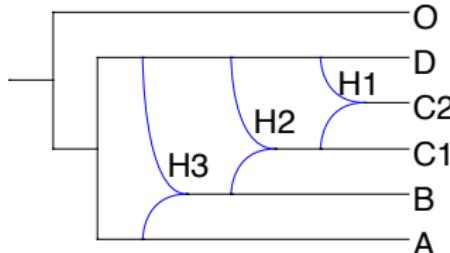
- Réseau A :  $k = 1$   $O(n^8)$ ,  $k' = 2$   $O(n^6)$
- Réseaux B et C :  $k = 2$   $O(n^{12})$ ,  $k' = 3$   $O(n^8)$

# Réseaux de la famille C

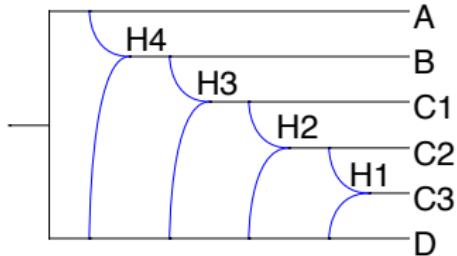
Réseaux avec 3 ou 4 noeuds de réticulations, et avec ou sans Outgroup O



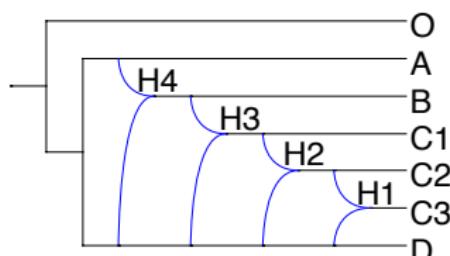
Réseau C(3) sans O



Réseau C(3) avec O



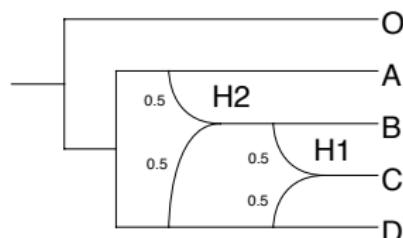
Réseau C(4) sans O



Réseau C(4) avec O

# Comparaison des temps de calcul de la vraisemblance $\mathbb{P}(\text{Data} | N)$

Dataset ID	CPU time	
	SNAPPNET (en minutes)	MCMCBiMarker (en heures)
1	5.559	35.9354
2	5.6763	34.2433
3	5.7351	32.6519
4	5.446	34.2011
5	5.5996	33.2354



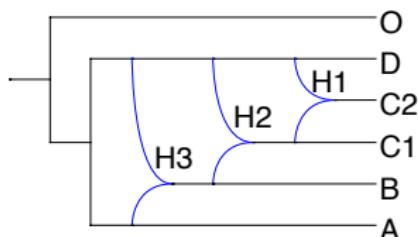
Réseau C de niveau 2

SNAPPNET vs MCMCBiMarker  
(Zhu et al., Plos Comp Biol 2018)

$O(n^8)$  vs  $O(n^{12})$

# Comparaison des temps de calcul de la vraisemblance $\mathbb{P}(\text{Data} | N)$

Dataset ID	CPU time	
	SNAPPNET (en minutes)	MCMCBiMarker (en heures)
1	23.75	> 336
2	25.14	> 336
3	25.31	> 336
4	24.90	> 336
5	25.15	> 336



Réseau C(3)

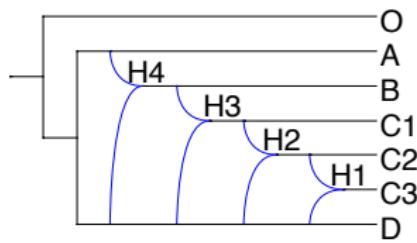
SNAPPNET vs MCMCBiMarker

(Zhu et al., Plos Comp Biol 2018)

$O(n^8)$  vs  $O(n^{16})$

# Comparaison des temps de calcul de la vraisemblance $\mathbb{P}(\text{Data} | N)$

Dataset ID	CPU time	
	SNAPPNET (en minutes)	MCMCBiMarker (en heures)
1	69.72	> 336
2	66.91	> 336
3	70.13	> 336
4	69.36	> 336
5	69.38	> 336



Réseau C(4)

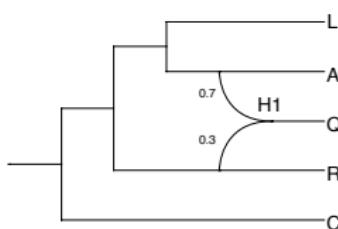
SNAPPNET vs MCMCBiMarker

(Zhu et al., Plos Comp Biol 2018)

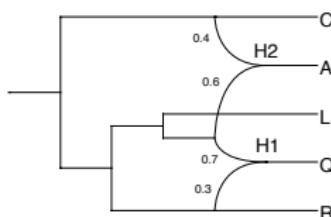
$O(n^8)$  vs  $O(n^{20})$

# Capacité de SNAPPNET à retrouver la topologie des réseaux A et B

Nombre de sites	1,000	10,000	100,000
Réseau A	0%	100%	100%
Réseau B	0%	81.25%	100%



Réseau A



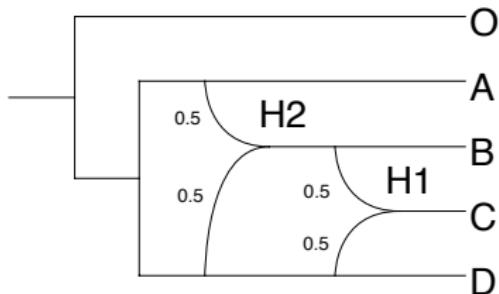
Réseau B

- 1000 sites : MCMCBiMarker > SNAPPNET
- $\geq 10000$  sites : SNAPPNET  $\approx$  MCMCBiMarker
- 10 000 sites requis pour inférer ces réseaux

# Capacité à retrouver la topologie du réseau C

SNAPPNET vs MCMCBiMarker

Nb lignées pour B et pour C	Nombre de sites		
	1,000	10,000	100,000
1	0%	7.87%	54.90%
	0%	4.84%	0%
4	0%	50.00%	49.60%
	0%	0%	0%

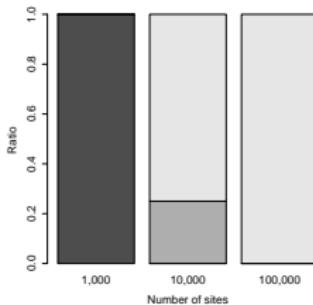


Réseau C

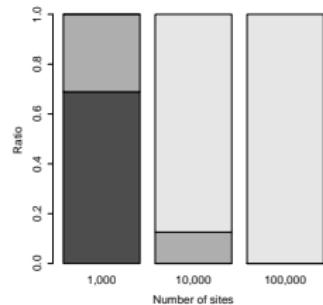
# Réseaux échantillonnés lors du MCMC

Ratio arbres / réseau à 1-reticulation / réseau à 2-reticulations

1 ligne pour B et C

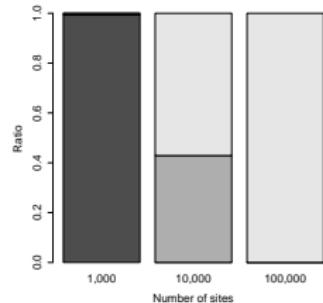
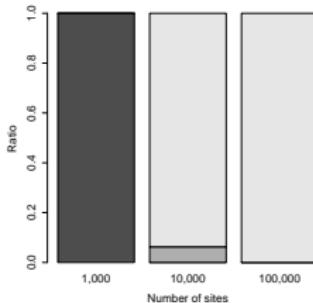


SNAPPNET



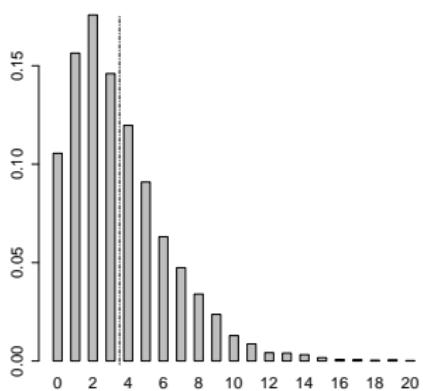
MCMCBiMarkers

4 lignées pour B et C

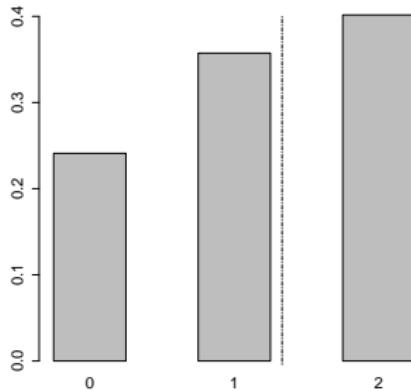


# A propos du processus de naissance hybridation dans SNAPPNET (Zhang et al., MBE 2018)

Distribution du nombre de réticulations



Sans contrainte



en bornant à 2 réticulations

Afin de limiter l'espace d'exploration  $\Rightarrow$  un maximum de 2 réticulations

dans MCMCBiMarker : a priori basé sur graphes  
de recombinaison ancestrale

# Capacité de SNAPPNET à retrouver la topologie en fonction de l'a priori sur les tailles de population

Vraie valeur  $\theta = 0.005$

$$\theta \sim \Gamma(1, 200)$$

$$\mathbb{E}(\theta) = 0.005$$

<b>Nombre de sites</b>	1,000	10,000	100,000
<b>Réseau A</b>	0%	100%	100%
<b>Réseau B</b>	0%	81.25%	100%

$$\theta \sim \Gamma(1, 1000)$$

$$\mathbb{E}(\theta) = 0.001$$

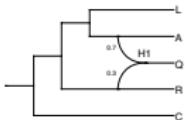
<b>Nombre de sites</b>	1,000	10,000	100,000
<b>Réseau A</b>	0%	94.73%	91.30%
<b>Réseau B</b>	0%	80%	95.65%

$$\theta \sim \Gamma(1, 2000)$$

$$\mathbb{E}(\theta) = 0.0005$$

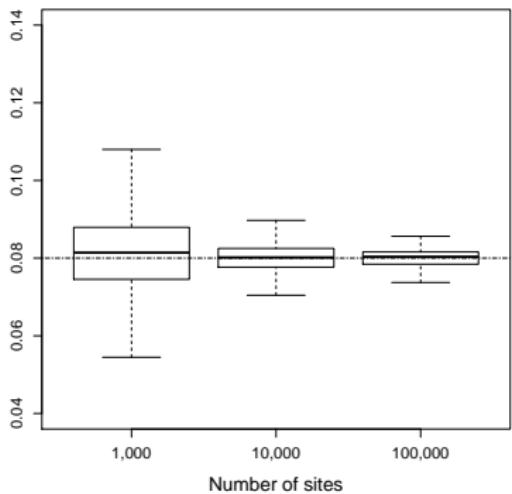
<b>Nombre de sites</b>	1,000	10,000	100,000
<b>Réseau A</b>	0%	100%	80%
<b>Réseau B</b>	0%	85%	85.71%

# Estimation des paramètres continus par SNAPPNET

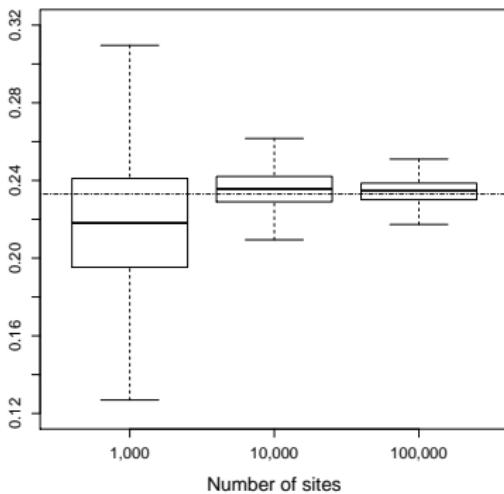


2 variétés par espèces

Réseau A

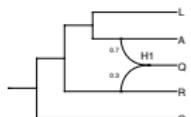


Hauteur du réseau



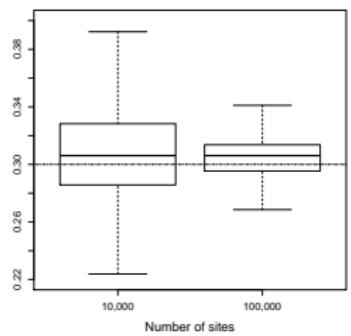
Longueur du réseau

# Estimation des paramètres continus par SNAPPNET

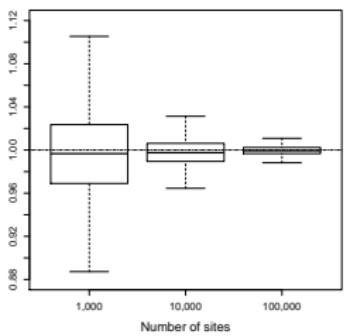


Réseau A

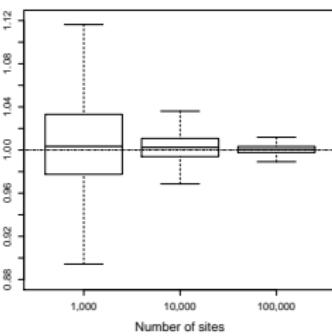
2 variétés par espèces



Probabilité d'hybridation  $\gamma$

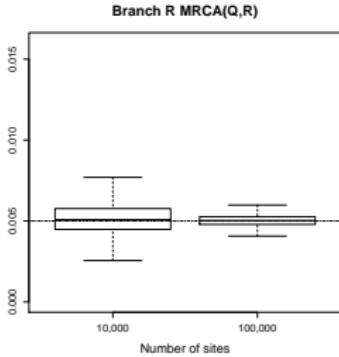
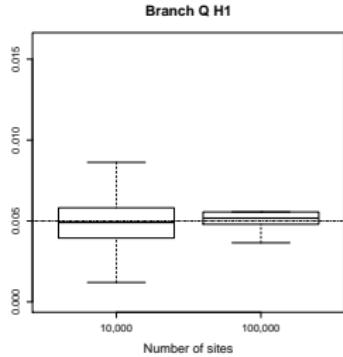


Taux instantané  $u$

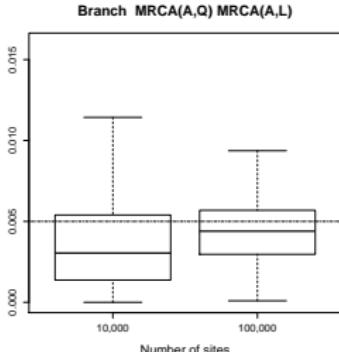
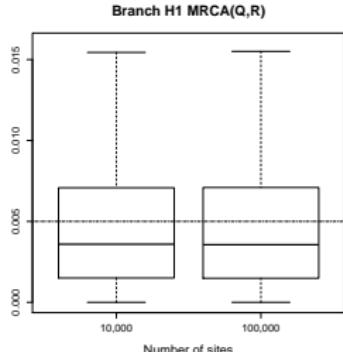


Taux instantané  $v$

# Les tailles de population récentes sont plus facilement estimables



- 2 branches externes



- 2 branches internes

# A propos des sites polymorphes

Les sites polymorphes sont utiles pour la reconstruction de réseau  
(Zhu et al, 2018)

Inference de la topologie du réseau A par SNAPPNET

- 1000 sites polymorphes
  - Le taux de reconstruction est désormais de 94.45%
  - Si on oublie de conditionner, le taux de reconstruction chute à 23.81%
- $\geq 10000$  sites : le taux de reconstruction est proche de 100% avec ou sans conditionnement

Paramètres continus :

- Estimations semblables à celles obtenues dans l'expérience incluant les sites invariants
- Si on oublie de conditionner : longueur et hauteur biaisés, taux  $u$  et  $v$  non biaisés

# Indiquez à SNAPPNET si vous avez conservé ou non les sites polymorphes

BEAUTi 2: OurSnappNetProjectTemplate

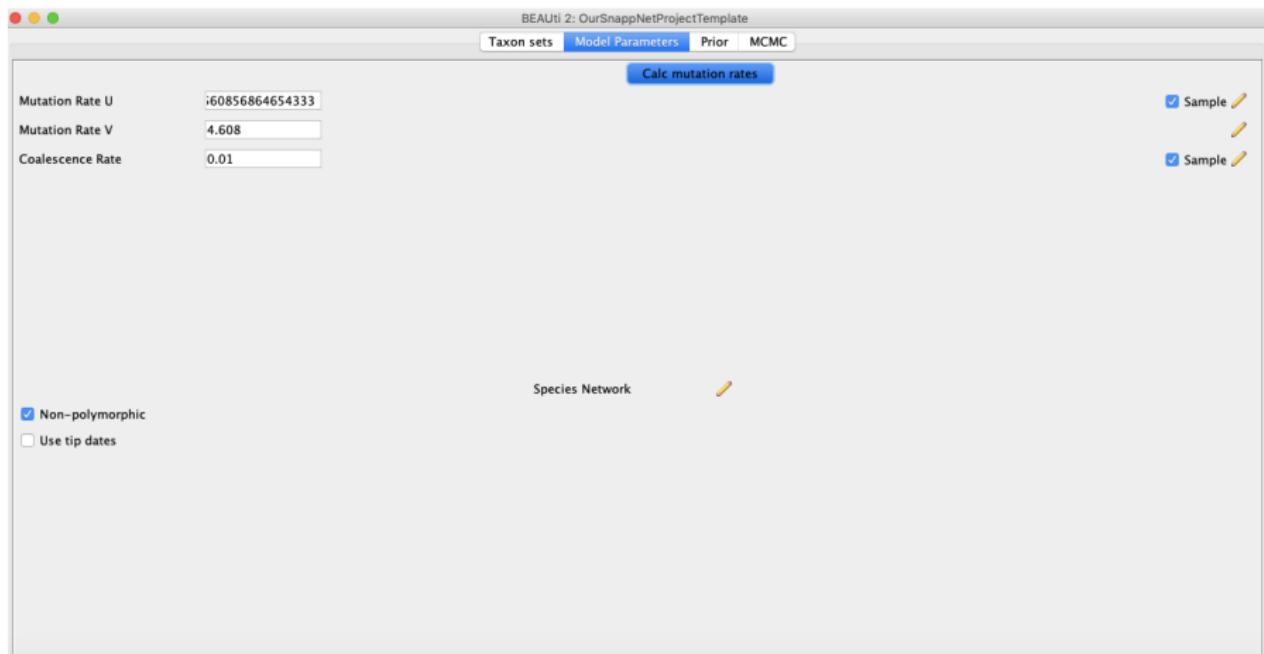
Taxon sets Model Parameters Prior MCMC

**Calc mutation rates**

Mutation Rate U	i60856864654333	<input checked="" type="checkbox"/> Sample
Mutation Rate V	4.608	<input checked="" type="checkbox"/> Sample
Coalescence Rate	0.01	<input checked="" type="checkbox"/> Sample

Species Network

Non-polymorphic  
 Use tip dates

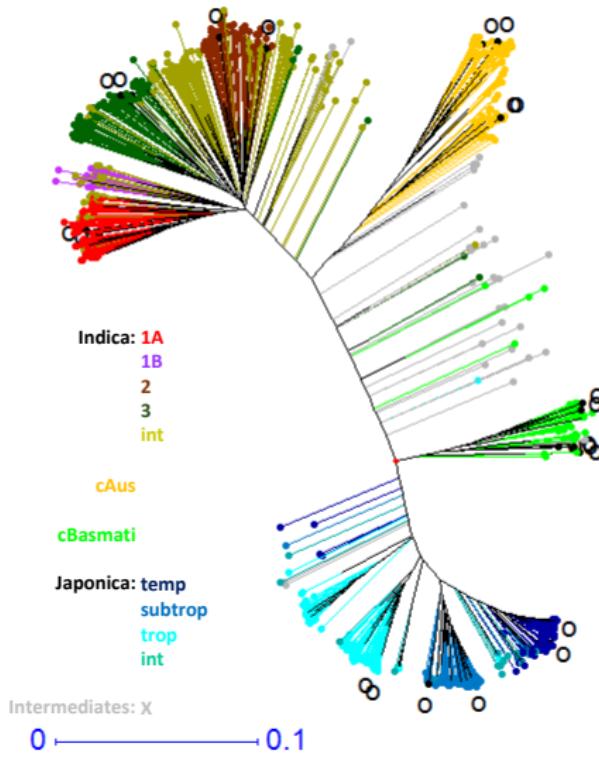


# Plan

- 1 Introduction
- 2 Inférence d'arbres d'espèces + arbres résumés en réseaux
  - La méthode SNAPP
  - Données réelles de riz
  - Données simulées
- 3 Inférence directe de réseaux
  - Méthodes existantes
  - La nouvelle méthode SNAPPNET
    - Calcul de vraisemblance + algorithme
    - A priori sur le réseau
    - BEAST (Beauti)
    - Opérateurs pour le Markov Chain Monte-Carlo
  - Comparaison SNAPPNET vs MCMCBiMarker
  - Données réelles de riz
- 4 Conclusion

# 24 variétés sélectionnées par J.C. Glaszmann

Arbre neighbour joining basé sur Wang et al. (Nature, 2018), 3000 variétés de riz (4.8 millions de SNPs)



# 24 variétés sélectionnées par J.C. Glaszmann

Sub-populations	Dataset	Variety ID	Country	Variety name
<i>circum Aus</i>	1	IRIS-313-11058	Bangladesh	AUS 329
		IRIS 313-11737	India	CHUNDI
	2	IRIS-313-10852	India	ARC 7336
		IRIS-313-11027	Pakistan	JHONA 101
<i>circum Basmati</i>	1	IRIS-313-11062	Bangladesh	BEGUNBICHI 33
		IRIS-313-11825	India	HANSRAJ
		IRIS-313-8326	India	JC1
	2	IRIS-313-11258	India	ARC 13502
		IRIS-313-10851	India	ARC 7296
		IRIS-313-12094	Bangladesh	ARC KASHA
<i>Indica</i>	1	IRIS-313-11819	Myanmar	PADINTHUMA
		IRIS-313-11796	China	DU GEN CHUAN
		IRIS-313-11089	Cambodia	SRAU THMOR
	2	IS-313-11646	India	NCS771 A
		CX270	Taiwan	TAICHUNG NATIVE1
		IRIS-313-11741	SriLanka	HERATH BANDA
<i>Japonica</i>	1	B204	China	LONGHUAMA OHU
		IRIS-313-11924	Thailand	NAM JAM
		IRIS-313-10577	Philippines	IFUGAO RICE
	2	IRIS-313-11691	Bhutan	SHANGYIPA
		IRIS-313-7883 B269	Indonesia China	GANIGI YUEFU

Dataset 1 : de l'Inde aux Philippines, Dataset 2 : du Pakistan à l'Indonésie

# 24 variétés sélectionnées par J.C. Glaszmann

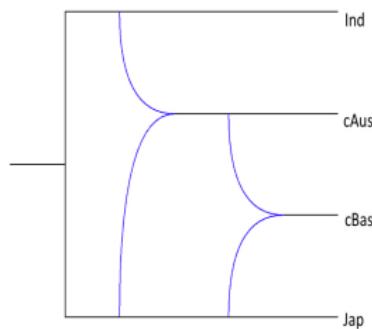
Dataset 1 : de l'Inde aux Philippines, Dataset 2 : du Pakistan à l'Indonésie



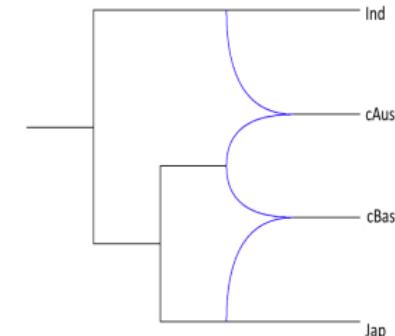
source <http://axl.cefan.ulaval.ca/>

# Les dix réseaux riz étudiés

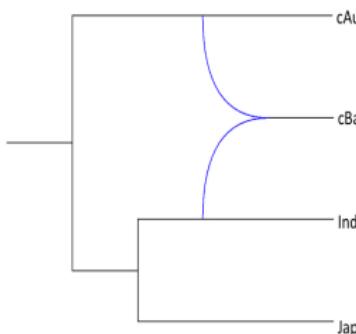
Réseau 1



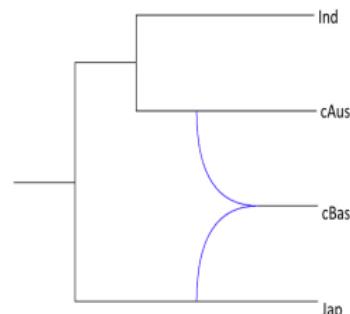
Réseau 2



Réseau 3 (peu conforme aux attentes)

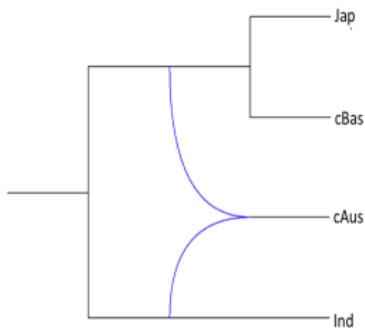


Réseau 4 (le plus conforme aux attentes)

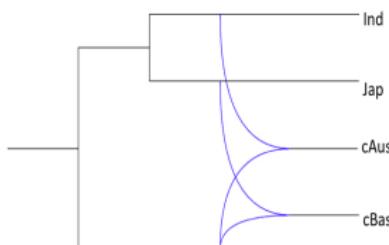


# Les dix réseaux riz étudiés

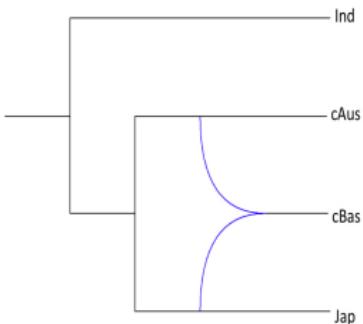
Réseau 5



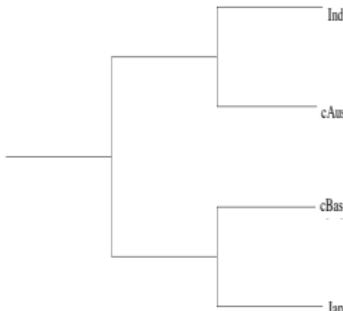
Réseau 6



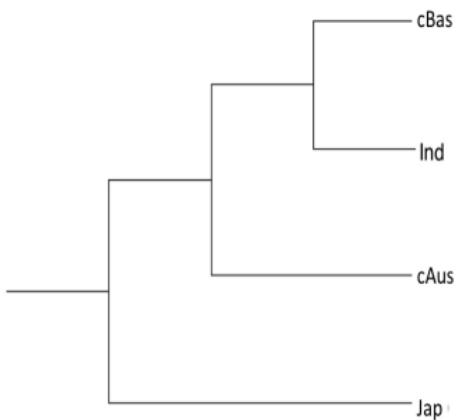
Réseau 7



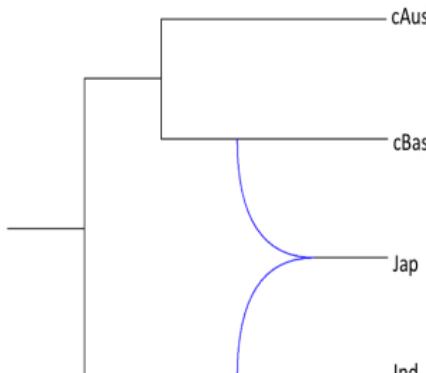
Réseau 8 (conforme aux attentes)



# Les dix réseaux riz étudiés



Réseau 9



Réseau 10 (peu conforme aux attentes)

# Calcul de vraisemblance pénalisée (AIC ou BIC) sur nos 10 reseaux

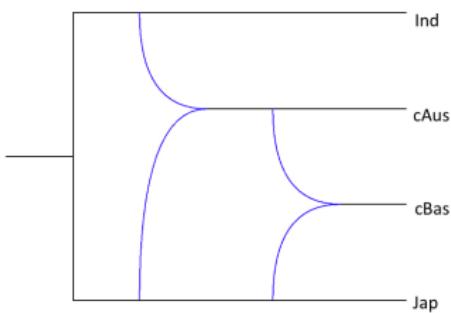
Network	Nb Parameters	Data set 1			Data set 2		
		Log Likelihood	AIC	BIC	Log Likelihood	AIC	BIC
1	29	-41699.09	83456.18 (2)	83670.57 (3)	-38860.03	77778.07 (1)	77992.45 (3)
7	22	-41724.92	83493.84 (3)	83656.48 (2)	-38878.57	77801.14 (4)	77963.78 (2)
4	22	-41669.73	83383.46 (1)	83546.10 (1)	-39036.92	78117.84 (6)	78280.48 (6)
2	29	-41755.40	83568.81 (4)	83783.19 (4)	-38867.12	77792.24 (2)	78006.63 (4)
10	22	-41936.12	83916.24 (7)	84078.88 (7)	-38878.48	77800.96 (3)	77963.60 (1)
5	22	-41921.53	83887.06 (6)	84049.70 (6)	-38964.73	77973.46 (5)	78136.10 (5)
6	29	-41874.35	83806.70 (5)	84021.09 (5)	-39040.20	78138.40 (7)	78352.79 (7)
3	22	-44264.72	88573.44 (8)	88736.08 (8)	-41197.22	82438.44 (9)	82601.08 (9)
8	15	-45586.44	91202.87 (10)	91313.76 (10)	-39209.63	78449.26 (8)	78560.15 (8)
9	15	-45041.92	90113.84 (9)	90224.73 (9)	-41498.45	83026.9 (10)	83137.79 (10)

# Calcul de vraisemblance pénalisée (AIC ou BIC) sur nos 10 reseaux

Network	Nb Parameters	Data set 1			Data set 2		
		Log Likelihood	AIC	BIC	Log Likelihood	AIC	BIC
1	29	-41347.93	82753.86 (1)	82968.25 (1)	-38493.86	77045.72 (1)	77260.11 (1)
7	22	-41387.08	82818.16 (2)	82980.80 (2)	-38531.24	77106.48 (2)	77269.12 (2)
2	29	-41464.70	82987.39 (3)	83201.78 (3)	-38543.21	77144.40 (4)	77358.79 (4)
10	22	-41625.53	83295.06 (6)	83457.70 (6)	-38546.30	77136.60 (3)	77299.24 (3)
4	22	-41597.64	83239.28 (5)	83401.92 (5)	-38686.75	77417.50 (6)	77580.14 (6)
6	29	-41542.08	83142.16 (4)	83356.55 (4)	-38690.65	77439.30 (7)	77653.69 (7)
5	22	-41669.71	83383.42 (7)	83546.06 (7)	-38658.04	77360.08 (5)	77522.72 (5)
8	15	-42353.95	84737.90 (8)	84848.79 (8)	-38940.40	77910.80 (8)	78021.69 (8)
3	22	-44009.53	88063.06 (9)	88225.70 (9)	-40851.45	81746.90 (9)	81909.54 (9)
9	15	-44790.69	89611.38 (10)	89722.27 (10)	-41141.28	82312.56 (10)	82423.45 (10)

# Rice evolution scenario inferred by SNAPPNET

- Average ranking : Net 1 > Net 7 > Net 2 > **Net 4** > **Net 10** > Net 5 > Net 6 > **Net 8** > **Net 3** > Net 9
- The proportion of **Japonica** present **in cBasmati genome** is approximately **73%** (agreement across analyses on networks 1, 7, 2 and 4)
- Network 1 is the rice evolution scenario inferred by SNAPPNET

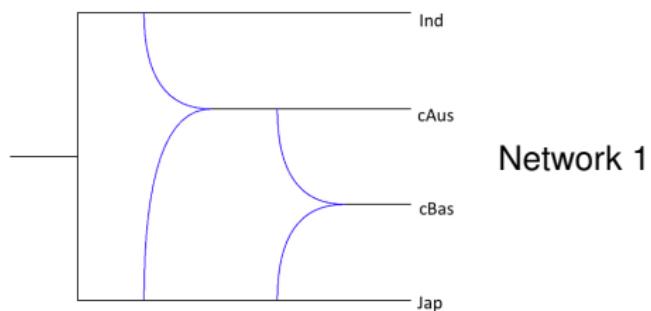


**cAus** : result of an early(old) combination between the *Ind* and the *Jap* lineages

**cBas** : a later combination between the *cAus* and the *Jap* lineages

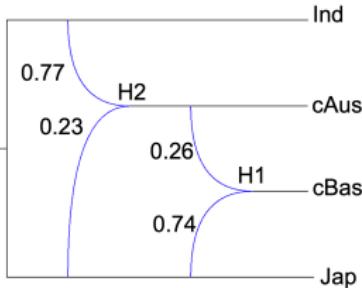
New scheme that appears compatible within the simpler schemes that have been proposed so far (e.g. *Choi et al, Genome Biology 2020*)

# Extra informations on the oldest reticulation

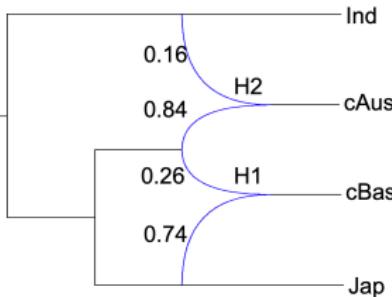


- Contributions to cAus : 77% from Indica and 23% from Japonica
- Compatible with the geographical distribution of the three groups :
  - cAus in the Northeastern part of the Indian subcontinent, contacts between South Asia and East Asia because of [the southern silk road](#) (Chakraborty et al., 2019)
- Possible explanation : [wide cross compatibility of the cAus varieties](#) which tends to make them fertile in crosses with both Indica and Japonica (Morinaga et al., 1955, 1958).

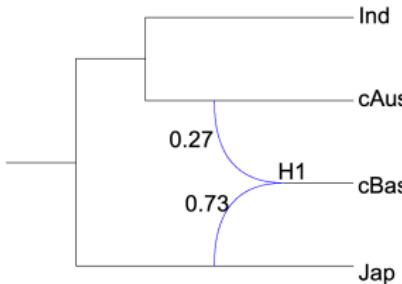
# Probabilités d'hybridation moyennées sur les 4 jeux de données



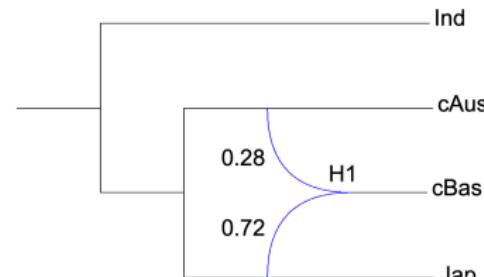
Réseau 1



Réseau 2



Réseau 4

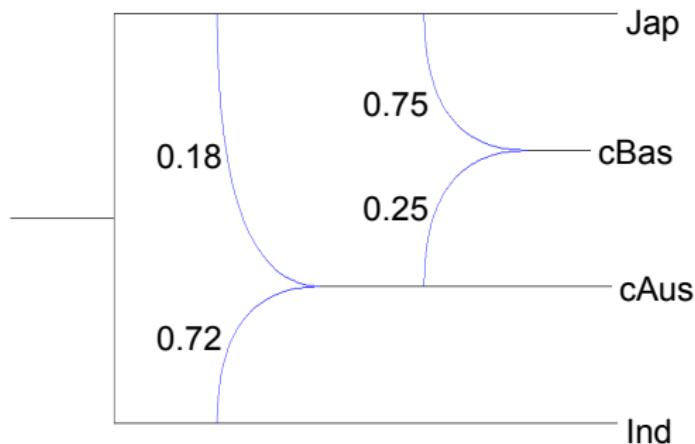


Réseau 7

# SNAPPNET en version MCMC

Dataset 1 :

- 1 174 000 itérations effectuées
- Effective Sample Size = 130
- SNAPPNET bloqué sur le Réseau 1



Dernier réseau échantillonné

mais une autre chaîne est sur un autre réseau

# Plan

- 1 Introduction
- 2 Inférence d'arbres d'espèces + arbres résumés en réseaux
  - La méthode SNAPP
  - Données réelles de riz
  - Données simulées
- 3 Inférence directe de réseaux
  - Méthodes existantes
  - La nouvelle méthode SNAPPNET
    - Calcul de vraisemblance + algorithme
    - A priori sur le réseau
    - BEAST (Beauti)
    - Opérateurs pour le Markov Chain Monte-Carlo
  - Comparaison SNAPPNET vs MCMCBiMarker
  - Données réelles de riz
- 4 Conclusion

# Conclusion

- Jusqu'alors travail sur le riz → autre plante d'intérêt ? Vigne, Sorgho, Banane, Citrus, Cafier, Canne à sucre ...
- SNAPPNET disponible sur <https://github.com/rabier/MySnappNet>
- Papier disponible sur biorxiv : "On the inference of complex phylogenetic networks by Markov Chain Monte-Carlo"
- Le tri de lignées incomplet (ILS) aide à la reconstruction de reseau (sans ILS, incapacité à retrouver le réseau C)
- Les gains en vitesse de calcul permettent de considérer des scénarios évolutifs plus complexes mais convergence du MCMC assez lente
- Package BEAST coupled MCMC (Mueller and Bouckaert, 2020), afin de sortir des optimums locaux grâce à des chaines chaudes et froides
- Le Multispecies Network Coalescent suppose l'indépendance entre les sites ⇒ étude de reseaux à l'intérieur de réseaux pour modéliser la recombinaison proprement (cf. Degnan, 2018)
- Etudier plus en détail le réseau 1 avec les 2 hybridations l'une sous l'autre
- Considérer plus de variétés par des approches ABC random forest (Pudlo et al, 2015)

# Remerciements

Céline Scornavacca



Vincent Berry

Fabio Pardi



Jean-Christophe Glaszmann

João D. Santos



Jean-Michel Marin



Angélique D'Hont  
Manuel Ruiz







