

INFÉRENCE DE RÉSEAUX PHYLOGÉNÉTIQUES PAR ABC-FORÊTS ALÉATOIRES (ABC-RF) : APPLICATION AU PROCESSUS DE DOMESTICATION DU RIZ

Charles-Elie Rabier^{1,2} & Jean-Christophe Glaszmann³

¹ IMAG, Université de Montpellier, CNRS, France

² Univ Angers, Institut Agro, INRAE, IRHS, SFR QUASAV, F-49000 Angers, France,
charles-elie.rabier@univ-angers.fr

³ CIRAD, UMR AGAP, Montpellier, France, Amélioration Génétique et Adaptation des
Plantes méditerranéennes et tropicales (AGAP), Université de Montpellier, CIRAD,
INRAE, Institut Agro, Montpellier, France, jean-christophe.glaszmann@cirad.fr

Résumé. Nous nous intéressons dans cette étude, à l’inférence de réseaux phylogénétiques par ABC-Forêts Aléatoires (ABC-RF). Les réseaux phylogénétiques sont des graphes dirigés acycliques, qui peuvent représenter des scénarios évolutifs. Le champ d’application porte ici sur l’histoire de domestication du riz en Asie. Ce processus de domestication fait l’objet de débats permanents dans la communauté scientifique. Notre travail, basé sur des données de séquences génomiques, se décompose en trois étapes successives. On commence tout d’abord par explorer librement l’espace entier des réseaux phylogénétiques, par la méthode SNAPPNET dans un cadre Bayésien (MCMC), sur de multiples petits jeux de données. A noter que SNAPPNET présente l’avantage d’intégrer sur toutes les histoires locales, i.e. sur tous les arbres de locus. Suite aux nombreuses et diverses hybridations obtenues, nous constatons qu’il s’avère impossible de dégager un réseau phylogénétique faisant consensus entre jeux de données. Nous proposons dès lors, en deuxième étape, de nous concentrer sur 16 réseaux phylogénétiques plausibles, tout en augmentant le nombre de séquences. Avec l’aide de SNAPPNET dans un cadre de vraisemblance pénalisée, on extrait les 6 meilleurs réseaux. Enfin, afin de pouvoir voter pour un unique scénario en s’appuyant sur un jeu de données encore plus conséquent, nous présentons une étude ABC-RF basée sur des statistiques résumées inspirées par la littérature réseaux phylogénétiques. Nos statistiques résumées sont calculées sous le “*Network Multispecies Coalescent*” et implémentées au sein de notre simulateur SIM-SNAPPNET. Les distributions a priori sont calibrées à l’aide des estimations de paramètres obtenus à l’étape deux. Nous montrons qu’ABC-RF semble présenter un potentiel intéressant pour l’inférence de réseaux phylogénétiques sous le “*Network Multispecies Coalescent*”.

Mots clés. ABC-Forêts Aléatoires, Réseaux phylogénétiques, Evolution, MCMC, Vraisemblance pénalisée, Statistique Bayésienne

Abstract. We focus here on phylogenetic network inference by means of the ABC-Random Forest method. The application field is the rice domestication process in Asia. We present here a methodological study based on a rich stochastic model, that incorporates introgression events, incomplete lineage sorting, and mutations that happen over time. Our study, relying on genomic data, consists in three steps. First, as a preliminary analysis, we explore freely the whole space of evolutionary scenarios, thanks to SNAPPNET in a Bayesian framework. Since it was impossible to draw a consensus phylogenetic network from the large diversity of inferred evolutionary histories, we propose in a second step, to concentrate on 16 rice evolutionary scenarios of interest. It enables us to handle more sequences simultaneously and to focus on a few domestication histories. With the help of SNAPPNET in a penalized

likelihood framework, we evaluate the likelihoods of the different phylogenetic networks and we select the best networks according to the AIC criteria. Last but not least, in a third step, we present an ABC-RF study, relying on an even larger data set and on summary statistics inspired by phylogenetic network literature. Our summary statistics are computed under the “*Network Multispecies Coalescent*”, and implemented within our simulator SIMSNAPPNET. Parameter values for the different prior distributions are chosen, thanks to SNAPPNET’s estimations at step two. This ABC-RF study allows us to discriminate among the six best scenarios found by SNAPPNET at step two.

Keywords. ABC-Random Forest, Phylogenetic networks, Evolution, Monte Carlo Markov Chain, Penalized likelihood, Bayesian statistics

1 Introduction et feuille de route

Les bouleversements impressionnants en biotechnologie ont généré un flot de données considérable permettant l’exploration systématique du vivant, à différentes échelles d’organisation et le recours croissant en biologie à la modélisation mathématique et aux sciences du numérique. Un défi actuel est de concevoir des méthodes statistiques, reposant sur des modèles biologiques complexes, tout en exploitant le volume considérable de données, comme par exemple les nombreuses séquences génomiques. Il s’avère désormais acquis que les données génomiques résultent d’une histoire évolutive riche, que se soit localement (marqueur SNP, ou gène) ou globalement (à l’échelle du génome). Au niveau local, on peut mentionner le tri de lignées incomplet (cf. Ebersberger et al., 2007) ou les transferts horizontaux de gènes (e.g. bactéries, fungi, Szollosi et al., 2015), deux événements évolutifs, responsables de la discordance entre arbres de gènes et arbres d’espèces (Rokas et al., 2003). Au niveau de l’histoire globale des génomes, soulignons l’hybridation (assez fréquente chez les plantes), événement évolutif qui intervient lorsque des individus appartenant à deux populations génétiquement différentes se reproduisent, créant une nouvelle population. Les approches basées sur les réseaux phylogénétiques (Huson et al., 2010) permettent la détection d’événements d’évolution réticulée, et donc la détection d’hybridation.

Bien que les méthodes proposées dans notre présente étude s’avèrent relativement génériques, on choisira comme champs applicatif, le processus de domestication du riz en Asie. Il existe principalement quatre types de riz cultivés, à savoir Japonica, Indica, circum Aus (cAus), et circum Basmati (cBasmati). Le processus de domestication du riz en Asie fait l’objet de perpétuels débats et plusieurs thèses s’opposent, à savoir une seule domestication (e.g. Huang et al., 2012, Wu et al., 2023), ou de multiples domestications (e.g. Civan et al., 2015, Jing et al., 2023). Afin d’approfondir la question de la domestication, notre étude dans sa globalité, se veut générale et sans a priori sur un scénario évolutif particulier.

Dans ce qui suit, on commencera par brièvement rappeler quelques méthodes statistiques de reconstruction de réseaux phylogénétiques. On s’attardera par la suite, sur le concept de calcul Bayésien approché (ABC) et d’ABC-Forêts Aléatoires (ABC-RF). Dans une deuxième partie, on décrira le modèle stochastique investi dans notre étude, et on présentera nos résultats.

2 Quelques méthodes statistiques de reconstruction de réseaux phylogénétiques

Les réseaux phylogénétiques (cf. Solis-Lemus et Ané, 2016) sont des graphes dirigés sans cycles dirigés et avec une seule racine, qui peuvent décrire les transferts horizontaux de gènes (e.g. bactéries), les phénomènes d’hybridations (e.g. plantes) ainsi que les introgressions (e.g. plantes et animaux). Les gènes sont transférés horizontalement lorsqu’ils sont acquis par une population à travers un processus autre que la reproduction. Les introgressions représentent l’intégration d’allèles d’une population dans une autre existante.

La reconstitution de réseaux phylogénétiques est un enjeu majeur car elle permet de répondre à de nombreuses questions soulevées par les biologistes. A l’heure actuelle, les méthodes de pseudo-vraisemblance et les méthodes Bayésiennes, toutes deux basées sur des modèles biologiques complexes, sont très populaires dans la reconstruction de réseaux phylogénétiques. Bien que les méthodes de pseudo vraisemblance soient approchées, elles présentent l’avantage de gérer de très gros jeux de données génomiques. Elles reposent sur deux étapes. Le réseau est tout d’abord divisé en sous réseaux avec un petit nombre de feuilles (i.e. espèces), puis la vraisemblance de chaque sous-réseau est calculée. Dans un deuxième temps, ces vraisemblances sont combinées afin d’obtenir une “pseudo-vraisemblance” du réseau phylogénétique entier (e.g. SNAQ de Solis-Lemus et Ané (2016) et Zhu et al. (2019)).

D’autre part, les méthodes Bayésiennes sont très prisées car elles fournissent une distribution de réseaux, pour lesquels on peut explorer l’incertitude sur les différents clade. La première méthode Bayésienne a été proposée par Wen et al. (2016). Par la suite, les méthodes SPECIESNETWORK de Zhang et al. (2017) et MCMCBIMARKERS de Zhu et al. (2018) ont été implémentées dans la plateforme BEAST 2 (Bouckaert et al., 2019) et dans PHYLONET (Wen et al., 2018), respectivement. Plus récemment, nous avons proposé la méthode SNAPPNET (Rabier et al., 2021) qui est basée exactement sur le même modèle mathématique que MCMCBIMARKERS, excepté que les deux méthodes considèrent différentes distributions a priori pour le réseau. L’avantage de SNAPPNET sur MCMCBIMARKERS, vient du fait que le calcul de vraisemblance est largement plus rapide avec SNAPPNET, de par le traitement mathématique. En particulier, SNAPPNET calcule des probabilités jointes, alors que MCMCBIMARKERS est basée sur une approche combinatoire. La complexité du calcul de vraisemblance avec SNAPPNET est gouvernée par la scanwidth qui mesure le nombre maximal d’arêtes du réseau simultanément impliquées dans les calculs de probabilités jointes.

3 Le concept d’ABC-Forêts Aléatoires (ABC-RF)

Bien que SNAPPNET ait réduit considérablement les calculs de vraisemblance comparé à MCMCBIMARKERS, le calcul de vraisemblance s’avère coûteux avec SNAPPNET dès que l’on traite de nombreux individus par espèces (cf. Rabier et al., 2021). Ainsi, afin de traiter plus de données, nous proposons ici une étude originale par ABC-RF, s’appuyant sur des statistiques résumées inspirées de la littérature des réseaux phylogénétiques. Le modèle stochastique investi demeure identique à celui de SNAPPNET.

Avant de s’attarder sur le concept d’ABC-RF, rappelons tout d’abord l’approche ABC. ABC, pour “Approximate Bayesian Computation”, est une méthode computationnelle en statistique Bayésienne, qui permet d’approximer la distribution a posteriori. Contrairement aux méthodes Bayésiennes classiques comme SNAPPNET, les méthodes ABC (Rubin et al., 1984) présentent l’avantage de s’affranchir du calcul de vraisemblance (cf. Marin et al., 2012 pour une revue). Elles ont été motivées par la biologie (Tavaré et al., 1997, Pritchard et al., 1999) et sont très populaires en génétique des populations (e.g. Boitard et al., 2016, Jay et al., 2017). On recense également des applications en phylogénie (e.g. Saulnier et al., 2017, He et al., 2023).

Des approches ABC-Forêts Aléatoires (ABC-RF) ont été proposées par Pudlo et al. (2015), Raynal et al. (2019), Estoup et al. (2018) et ont déjà montré récemment tout leur potentiel applicatif (e.g. Chapuis et al., 2020, Gilabert et al., 2023). ABC-RF se distingue de l’ABC classique car elle ne prend pas en compte les distributions a posteriori traditionnellement utilisées. ABC-RF consiste à construire un classifieur sur la base du concept très célèbre des forêts aléatoires (Breiman, 2001) et d’une table de référence constituée d’un grand nombre de statistiques résumées. Par la suite, il est également possible d’approximer la probabilité a posteriori du modèle sélectionné.

ABC-RF s’avère bien moins difficile qu’ABC à mettre en oeuvre en terme de calibration. ABC-RF nécessite beaucoup moins de simulations à partir de la loi a priori car elle ne repose pas sur une méthode d’acceptation/rejet : on peut ainsi remplir aisément une table de référence basée sur un très grand nombre de statistiques résumées.

4 Description du modèle stochastique investi

Le modèle stochastique investi dans notre étude est le modèle sous-jacent à SNAPPNET et à MCMCBIMARKERS. C’est un modèle hiérarchique à plusieurs niveaux. Tout d’abord, le réseau phylogénétique reflète l’histoire réticulée globale des espèces. Par la suite, l’arbre de gènes symbolise l’histoire locale à une position du génome (i.e. à un site). Il est modélisé via un processus de coalescence qui évolue à l’intérieur du réseau phylogénétique. Cela traduit ainsi le tri de lignées incomplet. Enfin, le long des branches de l’arbre de gènes, un processus Markovien représente les mutations de l’ADN intervenant au fil du temps. On propose ci-dessous une description détaillée des différents étapes.

4.1 Réseaux phylogénétiques

Un réseau phylogénétique est un graphe dirigé acyclique. Les branches du réseau sont dirigées de haut en bas, de manière à avancer dans le temps. En d’autres termes, les ancêtres les plus anciens sont situés en haut du réseau alors que les feuilles se situent en bas. Un réseau phylogénétique présente deux types de noeuds. Un noeud est soit a) binaire avec une arête entrante et deux arêtes sortantes, ou b) dit de réticulation avec deux arêtes entrantes et une arête sortante. Dans le modèle de SNAPPNET, chaque branche du réseau a sa propre longueur mesurée en nombre de mutation attendues, et chaque branche a son propre paramètre de taille

de population.

4.2 Modèle pour l'arbre de gènes

Pour chaque site, l'arbre de gènes est obtenu suivant le “*Network Multispecies Coalescent*” (Yu et al., 2012). Le processus débute aux feuilles du réseau phylogénétique et remonte dans le temps, jusqu'à ce que toutes les lignées coalescent. Au départ, la coalescence a lieu entre les lignées qui appartiennent à la même espèce. 2 lignées coalescent avec taux $2\mu/\theta$, où μ and θ désignent respectivement un taux de mutation et un paramètre de taille de population propre à l'espèce. Si l'on assume que cette espèce est composée de k lignées, le premier temps de coalescence suit une loi exponentielle $\mathcal{E}(k(k-1)\mu/\theta)$, car la coalescence de chaque combinaison de 2 lignées est équiprobable. Lorsque $k = 2$, l'espérance du temps de coalescence est $\theta/(2\mu)$. θ est le nombre moyen de mutations, séparant 2 individus. Lorsque les lignées (qui n'ont pas pu coalescer) remonte à un noeud de spéciation délimitant deux espèces, les lignées sont regroupées et ont possibilité de coalescer le long de la nouvelle branche, en tenant compte de la valeur de θ associée à cette branche. Lorsque les lignées (qui n'ont pas pu coalescer) remontent à un noeud de réticulation, chaque lignée choisit indépendamment son origine ancestrale (modèle de Yu et al., 2011), selon une loi de Bernoulli de paramètre γ .

Pour finir, au dessus de la racine du réseau phylogénétique, la coalescence intervient entre toutes les lignées et le processus se termine lorsqu'uniquement une seule lignée ancestrale est restante. Comme son cousin SNAPP (Bryant et al., 2012), SNAPPNET considère $\mu = 1$ (cf. explications ci-dessous).

4.3 Modèle de mutation

Comme SNAPP, SNAPPNET considère des marqueurs bialléliques et les couleurs *rouges* et *vertes* représentent les deux allèles. Les marqueurs évoluent le long des branches des arbres de gènes, selon une chaîne de Markov à temps continu, où u et v dénotent respectivement les taux instantanés de muter de rouge à vert, et de vert à rouge. Sous ce modèle, pour une branche de longueur T , il y a en moyenne $2uvT/(u+v)$ mutations. Alors, le taux de mutation μ est de $2uv/(u+v)$. Imposer la contrainte $2uv/(u+v) = 1$ (i.e. $\mu = 1$), permet de mesurer les longueurs de branche en taux de substitutions par site (i.e. distance génétique).

5 Nos résultats

Notre étude est composée de trois étapes.

On commence tout d'abord par explorer librement l'espace entier des scénarios évolutifs, par la méthode SNAPPNET dans un cadre Bayésien, sur de multiples petits jeux de données. Pour l'analyse par MCMC, sur chaque jeu de données, deux chaînes de Markov ont été considérées pour chaque échantillonnage de 12,000 marqueurs le long du génome. Suite aux nombreuses et diverses hybridations obtenues, nous constatons qu'il s'avère impossible de dégager un réseau phylogénétique faisant consensus entre jeux de données.

Nous proposons dès lors, en deuxième étape, de nous concentrer sur 16 scénarios évolutifs. Ainsi, en nous focalisant uniquement sur quelques scénarios, nous sommes en mesure de gérer plus de séquences simultanément. La plupart de ces 16 scénarios demeurent plausibles pour l’histoire évolutive du riz en Asie. Avec l’aide de SNAPPNET dans un cadre de vraisemblance pénalisée, on se propose d’évaluer les vraisemblances des 16 réseaux phylogénétiques puis de sélectionner les meilleurs réseaux selon le critère AIC. On illustre par la même occasion le concept de scanwidth qui gouverne la complexité de SNAPPNET. En effet, les réseaux considérés présentent un, deux, ou trois noeuds de réticulation. A noter que SNAPPNET présente l’avantage d’intégrer sur tous les arbres gènes dans son calcul de vraisemblance.

Pour finir, afin d’être en mesure d’explorer un plus grand jeu de données, nous présentons une étude ABC-RF basée sur des statistiques résumées inspirées par la littérature réseaux phylogénétiques. Nos statistiques résumées sont calculées sous le “*Network Multispecies Coalescent*” (Yu et al., 2012) et implémentées au sein de notre simulateur SIMSNAPPNET (Rabier et al., 2021). Les valeurs des paramètres associés aux différentes distribution a priori pour ABC-RF sont choisies grâce aux estimation fournies par SNAPPNET à l’étape deux. Au final, nous avons considéré 8 combinaisons de distributions a priori, un total de 562 statistiques résumées et 84,000 simulations pour chaque combinaison. Dans tous les cas testés, le taux d’erreur a priori s’est avéré relativement faible pour chacun des scénarios, illustrant les bonnes performances du classifieur. Ainsi, l’ABC-RF couplé à un choix judicieux de statistiques résumées semble présenter un fort potentiel dans le cadre de réseaux phylogénétiques et du tri de lignées incomplet. Par la suite, sur les données réelles de riz, on montre qu’ABC-RF nous permet d’extraire le meilleur des six premiers scénarios suggérés par SNAPPNET à l’étape deux. Le scénario fortement retenu opte pour une seule domestication, celle de Japonica. Japonica aurait contribué par la suite à la domestication d’Indica et de cAus.

Bibliographie

- Civan, P., Craig, H., Cox, C. J., Brown, T. A. (2015). Three geographically separate domestications of Asian rice. *Nature plants*, 1, 15164.
- Marin, J. M., Pudlo, P., Robert, C. P., Ryder, R. J. (2012), Approximate Bayesian computational methods *Statistics and Computing*, 22(6), 1167-1180.
- Pudlo, P., Marin, J. M., Estoup, A., Cornuet, J. M., Gautier, M., Robert, C. P. (2015). Reliable ABC model choice via random forests. *Bioinformatics*, 32(6), 859-866.
- Rabier CE, Berry V, Stoltz M, Santos JD, Wang W, Glaszmann JC, Pardi F, Scornavacca C (2021). On the inference of complex phylogenetic networks by Markov Chain Monte-Carlo. *PLoS Computational Biology*. 17(9), e1008380.
- Solís-Lemus, C., Ané, C. (2016). Inferring phylogenetic networks with maximum pseudo-likelihood under incomplete lineage sorting, *PLoS genetics*, 12(3), e1005896.